



République Tunisienne  
Ministère de l'Enseignement Supérieur  
et la Recherche Scientifique  
Université de Carthage  
Institut national des sciences appliquées et  
de technologie



FILIÈRE : INFORMATIQUE INDUSTRIELLE ET AUTOMATIQUE

RAPPORT DE PROJET DE FIN D'ANNÉE

---

## Amélioration des images radiologiques des poumons pour aider à une meilleure prédition des maladies

---

*Par*

DEROUICHE OTHMEN

BEN ABDALLAH MOHAMED

HEDFI AYOUB

Encadrant académique : Bellamine Mohamed Sahbi

Examinateur : Ben Hatira Fafa

Année Universitaire : 2022-2023

# Remerciements

Tout d'abord, nous tenons à exprimer notre sincère gratitude à notre encadrant, Monsieur **Mohamed Sahbi Bellamine**, pour le soutien et les conseils tout au long de ce projet de fin d'année. Son expertise et son expérience nous ont été d'une grande aide dans la réalisation de ce travail.

Nous souhaitons aussi remercier la communauté des projets open-source, qui incarne l'esprit de coopération et d'ouverture. Leurs efforts incessants pour développer des solutions accessibles à tous ont permis une avancée significative dans le domaine de la technologie.

En outre, nous sommes également reconnaissants envers notre école, l'INSAT, qui nous donne chaque année de notre cursus académique l'opportunité de réaliser un projet de fin d'année qui dure des mois pendant lesquels on apprend pleins de détails qui nous sont certainement fructueux et enrichissants point de vue formation ingénieur.

Finalement, comme ce travail a été réalisé en trinôme, nous nous remercions d'avoir été engagé dans ce projet et d'avoir une bonne entente tout au long du procès de réalisation.

# Table des matières

|   |           |
|---|-----------|
| <b>Remerciements</b>  | <b>1</b>  |
| <b>Introduction générale</b>  | <b>2</b>  |
| <b>1 État de l'art</b>  | <b>3</b>  |
| 1.1 Techniques d'amélioration des images . . . . .  | 3         |
| 1.1.1 Filtres de bruitage . . . . .   | 3         |
| 1.1.2 Amélioration du contraste . . . . .   | 4         |
| 1.1.3 Generative adversarial network (GAN) . . . . .  | 5         |
| 1.2 Approches existentes de detection . . . . .   | 6         |
| 1.2.1 Modèles de Deep Learning . . . . .  | 6         |
| 1.2.1.1 Perceptron multicouche (MLP) . . . . .  | 6         |
| 1.2.1.2 Réseaux neuronaux convolutionnels (CNN) . . . . .   | 8         |
| 1.2.1.3 Multi-classification . . . . .  | 8         |
| 1.2.2 Transfer learning-Apprentissage par transfert . . . . .   | 9         |
| 1.2.3 Les méthodes d'ensemble . . . . .   | 9         |
| 1.2.4 Conclusion . . . . .  | 10        |
| <b>2 Description des spécifications</b>   | <b>12</b> |
| 2.1 Context and motivation . . . . .  | 12        |
| 2.1.1 Automatisation du diagnostic des anomalies de la radiographie pulmonaire . . . . .  | 12        |
| 2.1.2 Remédier au manque d'expertise diagnostique dans les établissements de santé mal desservis . . . . .                            | 13        |
| 2.1.3 Améliorer le triage et la priorisation . . . . .  | 14        |
| 2.1.4 Faire progresser la recherche médicale et le développement . . . . .  | 14        |
| 2.1.5 Permettre la télémédecine et les soins de santé à distance . . . . .  | 15        |
| 2.1.6 Améliorer l'enseignement et la formation en radiologie . . . . .  | 15        |
| 2.2 Objectifs du projet . . . . .   | 15        |
| 2.3 Travaux en apport . . . . .   | 16        |
| 2.4 Limites . . . . .   | 17        |
| 2.4.1 Limite 1 : Variabilité de la présentation de la maladie - Défi pour un diagnostic précis des maladies thoraciques . . . . .     | 17        |
| 2.4.2 Limite 2 : Disponibilité d'un cadre unifié d'apprentissage profond pour la détection de maladies thoraciques multiples. . . . . | 18        |
| 2.5 Contributions . . . . .   | 18        |
| 2.6 Conclusion . . . . .  | 22        |

|  |           |
|--|-----------|
| <b>3 Méthodologie et Implementation</b>                                      | <b>23</b> |
| 3.1 Collecte des données et prétraitement . . . . .                          | 23        |
| 3.1.1 Collecte des Données via Kaggle . . . . .                              | 23        |
| 3.1.2 Prétraitement . . . . .  | 23        |
| 3.1.3 Redimensionnement des images . . . . .                                 | 23        |
| 3.1.4 Normalisation de l'image . . . . .                                     | 23        |
| 3.1.5 Division de l'ensemble de Données en deux parties distinctes . . . . . | 24        |
| 3.2 Techniques d'amélioration employées . . . . .                            | 24        |
| 3.2.1 Filtre de gabor . . . . .  | 24        |
| 3.2.2 Préprocesseur multi-niveaux basé sur le CNN . . . . .                  | 25        |
| 3.2.3 CLAHE . . . . .  | 26        |
| 3.3 Modèle de prédiction de la maladie . . . . .                             | 27        |
| 3.4 Evaluation . . . . .   | 31        |
| 3.5 Discussion . . . . .   | 32        |
| 3.6 Déploiement du modèle . . . . .  | 34        |
| 3.6.1 Architecture de l'interface graphique : . . . . .                      | 34        |
| 3.6.2 Etude de cas : . . . . .   | 35        |
| 3.7 Conclusion . . . . .   | 36        |
| <b>Conclusion générale</b>   | <b>38</b> |
| <b>Webographie</b>   | <b>39</b> |
| <b>4 Bibliographie</b>   | <b>39</b> |

# Table des figures

|      |  |    |
|------|--|----|
| 1.1  | représentation tridimensionnelle de la fonction de Gabor normalisée entre les valeurs 0 et 255 . . . . . | 4  |
| 1.2  | Transformation de l'histogramme de l'image . . . . .   | 5  |
| 1.3  | Les images créées par les Gans montrant leur évolution au fil du temps . . . . .                         | 6  |
| 1.4  | Architecture de Gan . . . . .  | 6  |
| 1.5  | Réseau de neurones . . . . .   | 7  |
| 1.6  | architecture réseau de neurones . . . . .  | 7  |
| 1.7  | architecture de CNN . . . . .  | 8  |
| 1.8  | Schéma explicatif d'une multiclassification . . . . .  | 8  |
| 1.9  | Approche traditionnelle vs. Approche de Transfert Learning . . . . .                                     | 9  |
| 1.10 | Schéma explicatif de la notion de MI model ensembling . . . . .  | 10 |
| 2.1  | Emploi du deep learning . . . . .  | 12 |
| 2.2  | Avancement de la recherche médicale . . . . .  | 14 |
| 2.3  | Intégration de la solution . . . . .   | 16 |
| 2.4  | Technique du Label smoothing . . . . .   | 19 |
| 2.5  | Effet du Label smoothing . . . . .   | 20 |
| 2.6  | Effet de CLAHE . . . . .   | 20 |
| 3.1  | Code source du banque de filtre . . . . .  | 24 |
| 3.2  | Extrait de la banque de filtre sous forme d'un fichier csv . . . . .                                     | 24 |
| 3.3  | Image améliorée pour certaines valeurs de paramètres du filtre . . . . .                                 | 25 |
| 3.4  | Représentation schématique du bloc préprocesseur . . . . .   | 25 |
| 3.5  | Architecture du modèle . . . . .   | 26 |
| 3.6  | Code source du CLAHE . . . . .   | 26 |
| 3.7  | Analyse histogramme . . . . .  | 26 |
| 3.8  | Résultat de l'image amelioré démontrant l'extraction ses caractéristiques . . . . .                      | 27 |
| 3.9  | Graphes acycliques dirigés (DAG) . . . . .   | 27 |
| 3.10 | Model hiérarchique . . . . .   | 29 |
| 3.11 | L'architecture du model . . . . .  | 29 |
| 3.12 | L'architecture du model VGG16 . . . . .  | 30 |
| 3.13 | Résultats obtenus . . . . .  | 32 |
| 3.14 | Généralisation du model . . . . .  | 33 |
| 3.15 | Diagramme explicatif de l'interface . . . . .  | 34 |
| 3.16 | Inscription d'un patient . . . . .   | 35 |
| 3.17 | Carte d'un patient . . . . .   | 35 |
| 3.18 | Coordonnées d'un patient . . . . .   | 36 |
| 3.19 | Vue globale de l'interface . . . . .   | 36 |

# Introduction générale

Les maladies thoraciques englobent un large éventail de conditions qui affectent les organes du thorax, tels que les poumons, le cœur, les voies respiratoires et la cage thoracique. Ces affections peuvent avoir des conséquences graves pour la santé et nécessitent souvent une détection et un traitement précoce pour améliorer les résultats cliniques. La détection précoce des maladies thoraciques revêt une importance cruciale, car de nombreux problèmes de santé associés à ces affections sont plus faciles à traiter lorsqu'ils sont détectés à un stade précoce.

Les médecins ont traditionnellement utilisé des techniques d'imagerie médicale telles que les radiographies, le CT-scans et les IRM pour évaluer les organes thoraciques et identifier les anomalies. Cependant, l'interprétation de ces images nécessite souvent une expertise spécialisée et peut être sujette à des erreurs d'interprétation.

C'est là où le deep learning entre en jeu, en utilisant des réseaux de neurones convolutionnels (CNN), il est possible d'extraire automatiquement des informations pertinentes à partir des images radiographiques afin de détecter les différentes maladies thoraciques. Cette approche, permet de gagner du temps et de fournir des résultats plus précis et plus cohérents.

De surcroit, en utilisant des algorithmes de Deep Learning, nous pouvons surveiller les patients sur de grandes étendues et de manière régulière, permettant ainsi de détecter les risques à long terme et par conséquent de réagir rapidement en cas de situation critique.

Ainsi, le travail qui se présente à votre bienveillante appréciation se compose de trois parties, dont la première est consacrée à introduire les concepts de base ayant une relation étroite avec notre sujet. Quant à la seconde partie, elle est dédiée à présenter la motivation et les objectifs ainsi que la méthodologie de notre sujet . En ce qui concerne la troisième partie, on a expliqué les architectures d'apprentissage profond utilisées ainsi que quelques bout de codes et l'interface patient médecin .

# 1 | État de l'art

## 1.1 Techniques d'amélioration des images

Les techniques d'amélioration sont considérées comme des méthodes de prétraitement car elles agissent sur les images à un niveau d'abstraction bas, sans augmenter leur contenu informationnel mais en réduisant les distorsions indésirables ou en améliorant les caractéristiques pertinentes pour les tâches de traitement et d'analyse ultérieures.

Les techniques de prétraitement d'images se déclinent en quatre catégories principales :

1. Corrections de la luminosité des pixels / Transformations de la luminosité.
2. Transformations géométriques.
3. Filtrage et segmentation d'images.
4. Transformations de Fourier et restauration d'images.

### 1.1.1 Filtres de bruitage

— Filtre de Gabor :

Ce filtre tire son nom du mathématicien Dennis Gabor, qui l'a introduit dans le domaine du traitement du signal afin d'assurer la détection des contours d'une image.

$$g(x, y, \lambda, \theta, \psi, \sigma, \gamma) = e^{-\left(\frac{x'^2+y'^2}{2\sigma^2}\right)} \cdot \cos(2\pi \frac{x'}{\lambda} + \psi) \quad (\text{Équation de filtre de Gabor})$$

- Le filtre de Gabor est basé sur l'idée de combiner une onde sinusoïdale et une courbe en cloche (ou une fonction gaussienne) dans l'espace 2D. L'onde sinusoïdale est directionnelle, ce qui signifie qu'elle est sensible à la direction des contours. En combinant les deux, on obtient un filtre directionnel qui se concentre sur les contours dans une zone locale de l'image.

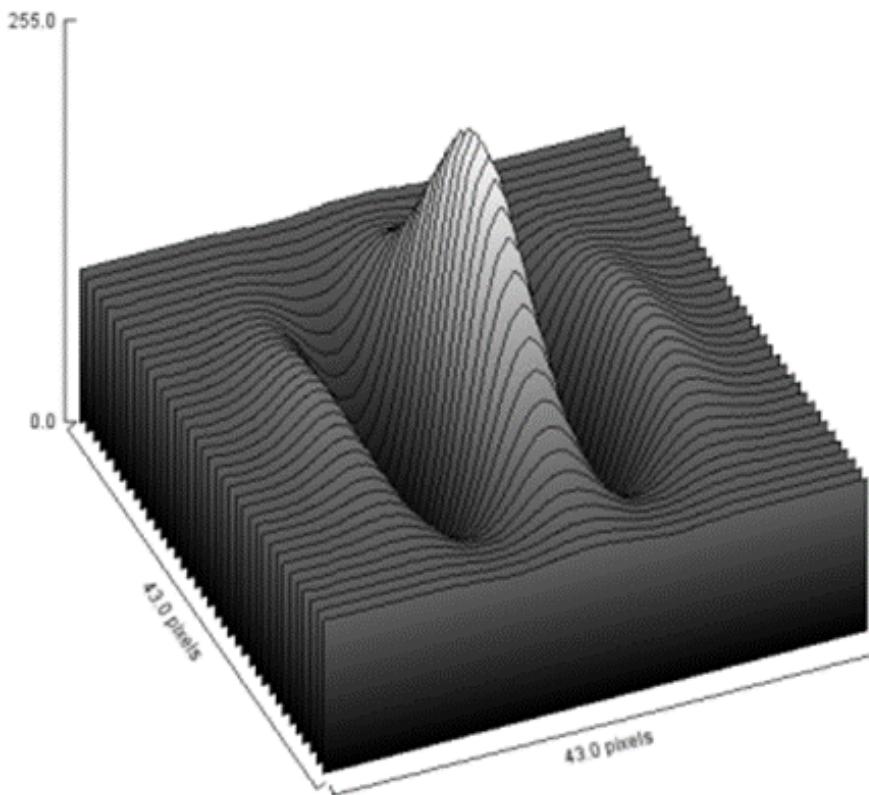


FIGURE 1.1 – représentation tridimensionnelle de la fonction de Gabor normalisée entre les valeurs 0 et 255

Les paramètres du filtre de Gabor jouent un rôle important dans la détection des contours :

- Sigma  $\sigma$  : l'écart-type de la courbe en cloche. Les valeurs plus petites mettent d'avantage l'accent sur les valeurs proches du centre, ce qui permet de détecter des contours plus fins.
- Theta  $\theta$  : Ce paramètre représente la direction de l'onde sinusoïdale du filtre afin de détecter les orientations
- Lambda  $\lambda$  : Il correspond à la longueur d'onde de l'onde sinusoïdale. Elle détermine la fréquence du filtre, c'est-à-dire la distance entre les pics de l'onde sinusoïdale.
- Gamma  $\gamma$  : Il représente l'ellipticité de la courbe en cloche. Il détermine le degré d'ellipticité de la forme du filtre.
- Psi  $\psi$  : Il définit le décalage de phase de l'onde sinusoïdale. Il permet de déplacer la position de l'onde sinusoïdale dans l'espace.

En ajustant ces paramètres, on peut obtenir différents filtres de Gabor adaptés à la détection de contours dans différentes orientations, échelles et formes.

### 1.1.2 Amélioration du contraste

- Egalisation histogramme : La technique de l'égalisation d'histogramme est employée en traitement d'images pour augmenter le contraste et améliorer l'apparence globale d'une image. Son principe repose sur la redistribution des valeurs d'intensité de l'histogramme de l'image, permettant d'obtenir une distribution plus uniforme des intensités . Il existe 2 Inconvénients majeurs à cette technique :

- Perte de détails : au niveau de certaines zones de l'image. Ainsi les différences subtiles d'intensité peuvent être perdues ou atténuées, d'où l'altération de la qualité de l'image.
- Sensibilité aux valeurs extrêmes : Lorsqu'une image possède des valeurs d'intensité extrêmement faibles ou élevées, l'égalisation de l'histogramme peut entraîner une saturation ou une perte de données dans ces zones. Cela peut conduire à une dégradation de l'image en introduisant des artefacts ou en provoquant une perte d'informations importantes .
- CLAHE :

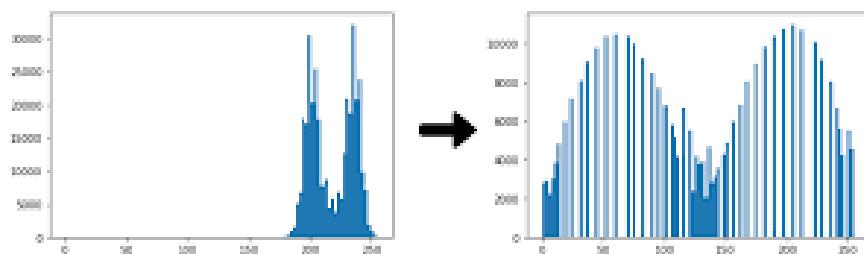


FIGURE 1.2 – Transformation de l'histogramme de l'image

Le CLAHE (Contrast Limited Adaptive Histogram Equalization) est une technique avancée couramment utilisée en traitement d'images pour améliorer le contraste global d'une façon adaptative en préservant les détails locaux de l'image.

Cette technique est constituée des étapes suivantes :

- la division de l'image en petites régions appelées "blocs".
- le calcul séparé de l'histogramme de chaque bloc
- Afin d'éviter une amplification possible du bruit, un contraste limité est appliqué à chaque bloc
- L'application d'une opération de redistribution sur chaque bloc en utilisant la technique d'égalisation d'histogramme adaptative. Cette opération répartit les valeurs d'intensité de manière plus uniforme dans chaque bloc, améliorant ainsi le contraste local.

### 1.1.3 Generative adversarial network (GAN)

Ian Goodfellow et ses collègues ont créé des modèles d'apprentissage automatique appelés Generative Adversarial Networks (GAN) en 2014 dans le but de produire des données réalistes. Les GAN sont des NN qui sont entraînés de manière opposée pour générer des données réalistes en reproduisant la même distribution. Voici quelques exemples d'images créées par les GAN.



FIGURE 1.3 – Les images créées par les Gans montrant leur évolution au fil du temps

Il existe deux catégories de modèles au niveau l'apprentissage automatique :

- Les modèles discriminatifs (D) : ils sont utilisés pour les problèmes de classification afin d'établir une distinction entre différentes classes.
- Les modèles génératifs (G) : ils sont formés pour faire correspondre un échantillon de bruit à un échantillon de données synthétiques.

Comme nous l'avons mentionné précédemment, les GAN sont des architectures de réseaux neuronaux profonds qui consistent en deux réseaux neuronaux, le premier étant un réseau génératif et l'autre un réseau discriminatif, en concurrence l'un avec l'autre, d'où le terme "contradictoire".

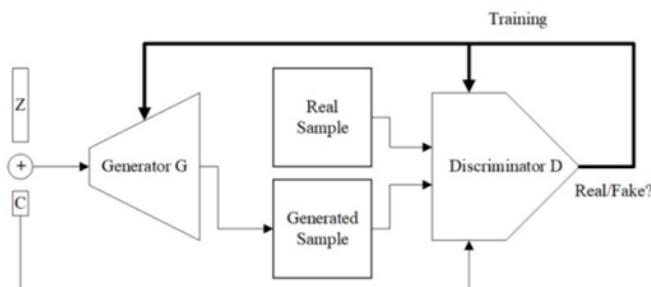


FIGURE 1.4 – Architecture de Gan

## 1.2 Approches existentes de detection

### 1.2.1 Modèles de Deep Learning

#### 1.2.1.1 Perceptron multicouche (MLP)

- Neural Network architecture :

Le réseau neuronal a été créé au début des années 1940 pour reproduire la façon dont le cerveau humain fonctionne. Le réseau neuronal fonctionne grâce à la présence de nombreux neurones dans notre cerveau qui ont la capacité de reconnaître ce qui nous entoure. Les réseaux neuronaux s'entraînent à partir d'un grand ensemble de données afin de trouver des modèles et de prédire correctement notre cible

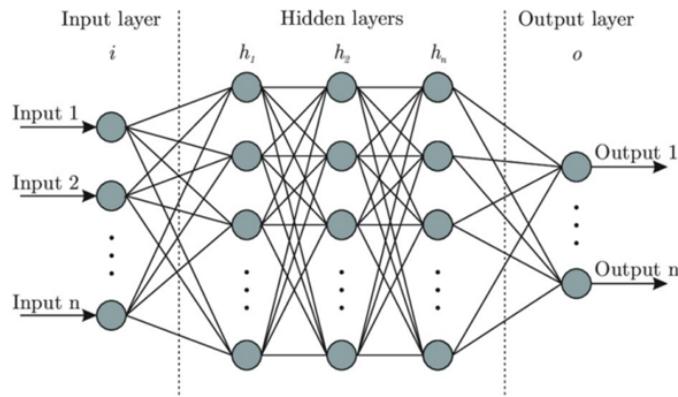


FIGURE 1.5 – Réseau de neurones

Un réseau neuronal se compose d'une couche d'entrée, d'une couche cachée et d'une couche de sortie, comme indiqué ci-dessous.

- Couche d'entrée : la valeur d'entrée ( $X$ ) fournie par les données est prise par les noeuds de cette couche.
- Les couches cachées sont utilisées pour effectuer des calculs spécifiques grâce à la fonction d'activation.
- Couche de sortie : comme son nom l'indique, cette couche fournit le résultat ( $Y$ ).

- Fonction d'activation :

Comme indiqué ci-dessus, les calculs dans les couches cachées utilisent des fonctions d'activation pour faire correspondre la somme pondérée à la sortie. Plusieurs fonctions d'activation sont disponibles, notamment tanh, ReLU, sigmoïde, etc.

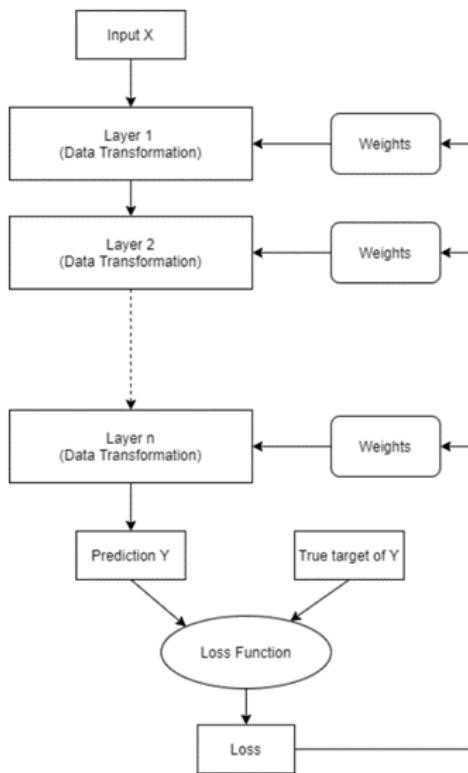


FIGURE 1.6 – architecture réseau de neurones

### 1.2.1.2 Réseaux neuronaux convolutionnels (CNN)

Un réseau neuronal de type feedforward (CNN) est constitué de plusieurs couches. En utilisant un filtre sur l'image d'entrée ou le son, les couches convolutives peuvent créer une image de synthèse qui représente une carte d'activation à  $n$  dimensions, comme indiqué à la figure. Il est communément admis que l'organisation des neurones des CNN est similaire à celle des cellules biologiques dans le cortex visuel.

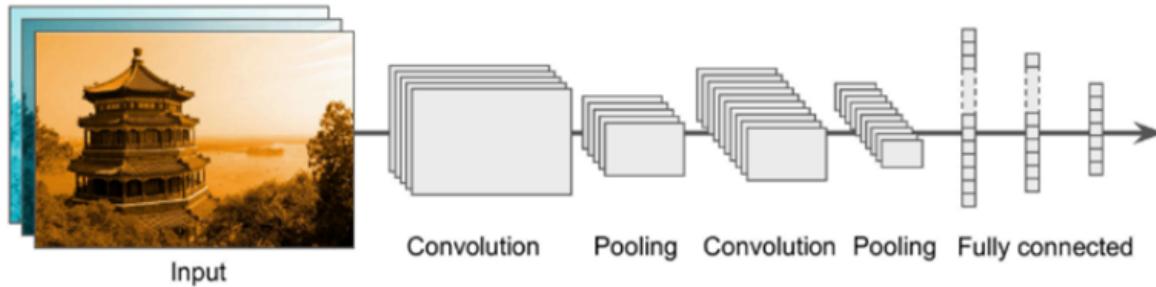


FIGURE 1.7 – architecture de CNN

L'utilisation de ce type de NN assure l'exploitation au maximum de la structure spatiale en captant les motifs locaux et les relations entre les pixels. De plus il permet de réduire le nombre de paramètres grâce l'opération de convolution.

### 1.2.1.3 Multi-classification

La classification multilabel implique l'attribution de plusieurs étiquettes à une instance de données par un modèle. Contrairement à la classification traditionnelle où une seule étiquette est assignée à chaque instance, cette classification permet à une instance d'appartenir à plusieurs classes simultanément.

Chaque étiquette dans la classification multilabel représente une classe ou une catégorie spécifique. L'objectif est de prédire les étiquettes appropriées pour chaque instance donnée. Par exemple, dans un système de recommandation de films, une instance peut être un film, et les étiquettes peuvent représenter différents genres tels que "comédie", "action" et "romance". Le modèle doit prédire les genres pertinents pour chaque film, ce qui peut inclure plusieurs étiquettes simultanément.



FIGURE 1.8 – Schéma explicatif d'une multiclassification

L'approche de réseaux de neurones pour aborder ce type de classification est celle qui nous intéresse . Elle consiste à adapter l'architecture du modèle en tenant compte de plusieurs étiquettes. Ainsi, des couches spécifiques, telles que les couches de sortie softmax ou les couches de sortie sigmoïde, sont utilisées pour générer des probabilités d'appartenance à chaque étiquette.

### 1.2.2 Transfer learning-Apprentissage par transfert

Avec l'avènement du Deep Learning, le Transfer Learning a rencontré un succès considérable. En effet, les modèles utilisés dans ce domaine exigent souvent des temps de calcul importants et des ressources considérables. Cependant, en utilisant des modèles pré-entraînés comme point de départ, le Transfer Learning offre la possibilité de développer rapidement des modèles performants et de résoudre efficacement des problèmes complexes en vision par ordinateur.

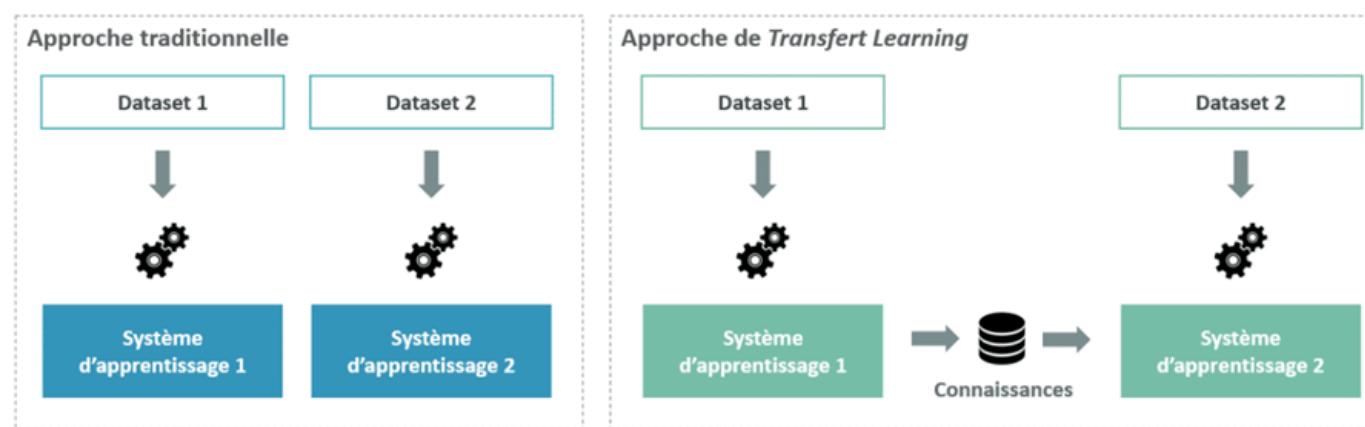


FIGURE 1.9 – Approche traditionnelle vs. Approche de Transfert Learning

- Exemple : Considérons le cas d'une personne qui possède des compétences en guitare et qui souhaite apprendre à jouer du piano. Elle peut tirer parti de ses connaissances musicales pour apprendre à jouer d'un nouvel instrument.

### 1.2.3 Les méthodes d'ensemble

L'ensemblling de modèles, également connu sous le nom de fusion de modèles ou l'agrégation des modèles , est une technique largement utilisée en Machine Learning pour améliorer la précision et la fiabilité des prédictions. Principe : il s'agit de combiner les prédictions de plusieurs modèles individuels afin d'obtenir une prédition finale plus précise et robuste.

La clé de cet assemblage réside dans la diversité des modèles utilisés. En effet, chaque modèle peut avoir ses propres forces et faiblesses. En combinant leurs prédictions, on peut tirer parti de la variété des approches pour obtenir une performance globale supérieure. Cette technique est particulièrement efficace lorsque les modèles individuels sont diversifiés et produisent des prédictions indépendantes les unes des autres.

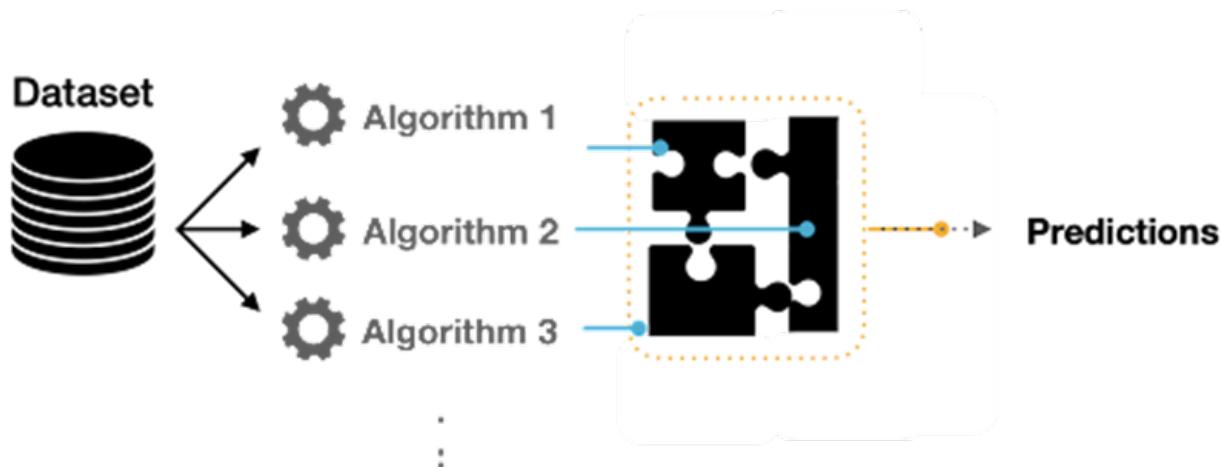


FIGURE 1.10 – Schéma explicatif de la notion de ML model ensembling

Différentes techniques d'ensembeling sont couramment utilisées dont on retrouve :

- Le vote majoritaire : Les prédictions des modèles individuels sont combinées en attribuant la classe majoritaire (ou la valeur prédite la plus fréquente) comme prédition finale.
- La moyenne pondérée : Les prédictions des modèles individuels sont combinées en utilisant une moyenne pondérée, où les poids sont assignés à chaque modèle en fonction de leur performance ou de leur fiabilité estimée.

### Le potentiel de l'intelligence artificielle dans le domaine médical

L'intelligence artificielle (IA) a le potentiel de révolutionner les pratiques de diagnostic et de traitement des maladies pulmonaires. Les applications prometteuses de l'IA dans ce domaine incluent :

- Détection et diagnostic précoce : Les algorithmes d'IA peuvent analyser les données provenant de scanners CT et repérer des anomalies subtiles qui pourraient indiquer une maladie potentielle. En identifiant ces changements à un stade précoce, l'IA peut contribuer à prévenir les maladies pulmonaires ou à en réduire la gravité .
- Traitement personnalisé : Les algorithmes d'IA peuvent examiner les données du patient, comme ses antécédents médicaux et les facteurs de risque, afin de personnaliser le traitement. Cela peut améliorer les résultats du traitement et réduire le risque de complications.
- La surveillance à distance des patients atteints de troubles respiratoires : est rendue possible grâce aux dispositifs alimentés par l'IA qui peuvent détecter les changements dans l'état de santé du patient et alerter les prestataires de soins de santé. Cela peut aider à les prévenir et à réduire les réadmissions à l'hôpital.

#### 1.2.4 Conclusion

Dans ce premier chapitre, nous avons présenté les concepts de base de l'intelligence artificielle (IA) et notamment son sous-domaine l'apprentissage profond (Deep Learning, DL). Nous avons examiné en premier lieu les opérations fondamentales du traitement d'image puis les différentes architectures existantes du réseau

neuronal qui seront des piliers par la suite dans notre réalisation pratique Nous avons également exploré les promesses de l'IA dans le domaine médical à savoir les diagnostic précoces, l'imagerie médicale et les assistants virtuels.

## 2 | Description des spécifications

### 2.1 Context and motivation

La radiographie du thorax est l'un des types d'examens de radiologie diagnostique les plus courants. Elle est essentielle pour le dépistage et le diagnostic de nombreuses maladies thoraciques. Des algorithmes spécialisés ont été développés pour détecter plusieurs pathologies spécifiques telles que les nodules pulmonaires ou le cancer du poumon.

Toutefois, la détection précise de la présence de plusieurs maladies à partir de radiographies du thorax (Chest X-Rays) reste une tâche difficile. C'est dans ce contexte que nous présentons nos motivations.

Les principales motivations qui sous-tendent le travail que nous proposons sont les suivantes :

#### 2.1.1 Automatisation du diagnostic des anomalies de la radiographie pulmonaire

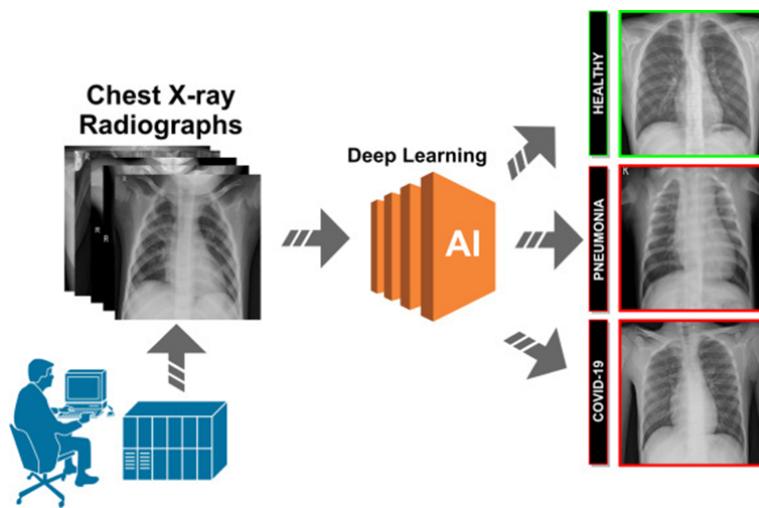


FIGURE 2.1 – Emploi du deep learning

Les radiographies du thorax sont largement utilisées en imagerie médicale pour détecter et diagnostiquer diverses maladies pulmonaires et thoraciques. Cependant, l'interprétation précise de ces images peut s'avérer difficile, même pour les radiologues expérimentés.

La distinction entre les différents types de pathologies peut s'avérer difficile en raison des similitudes de leurs caractéristiques visuelles.

Le développement d'un modèle d'apprentissage profond pour la classification et la localisation des maladies thoraciques courantes peut apporter une aide précieuse aux radiologues dans leur processus de prise de décision et contribuer à réduire les erreurs de diagnostic.

En automatisant l'identification d'anomalies ou de maladies spécifiques, telles que la pneumonie, les nodules pulmonaires ou la tuberculose, à partir d'images de radiographie thoracique, le modèle peut aider à établir des diagnostics plus rapides et plus précis.

Le modèle d'apprentissage profond agit comme un "second lecteur", servant de ressource supplémentaire pour les radiologues. Il fournit une méthode de haute précision pour classer et localiser les maladies thoraciques, agissant comme un outil précieux pour aider les radiologues dans leur interprétation.

En tirant parti de la puissance des algorithmes d'apprentissage profond, le modèle peut apprendre des modèles et des caractéristiques complexes à partir des images, améliorant ainsi la précision de la détection des maladies.

Disposer d'un système de classification et de localisation fiable et efficace en tant qu'outil d'assistance peut réduire considérablement les risques d'erreurs de diagnostic et améliorer le processus de diagnostic dans son ensemble. Il permet une prise de décision plus sûre et aide les radiologues à fournir des diagnostics rapides et précis.

### **2.1.2 Remédier au manque d'expertise diagnostique dans les établissements de santé mal desservis**

En outre, le modèle d'apprentissage profond proposé pour la classification des images de radiographie thoracique aborde la question de l'expertise diagnostique limitée dans certains établissements de santé, en particulier dans les zones rurales éloignées où l'accès à des radiologues spécialisés peut être limité ou indisponible.

Dans des pays comme la Tunisie, où l'infrastructure existe mais où les problèmes de personnel persistent, un tel modèle peut servir d'outil précieux pour combler le fossé et fournir des diagnostics précis en l'absence de spécialistes sur place.

En tirant parti de l'intelligence artificielle et de la technologie d'apprentissage profond, les professionnels de santé de ces régions mal desservies peuvent bénéficier d'interprétations fiables et opportunes des images de radiographie thoracique, ce qui permet d'améliorer les soins et les résultats pour les patients.

### 2.1.3 Améliorer le triage et la priorisation

L'utilisation d'un modèle de classification des radiographies thoraciques comme outil de dépistage offre des avantages significatifs dans les hôpitaux et les établissements de santé.

En tirant parti des capacités de classification automatisée, le système réduit efficacement les temps d'attente pour les patients, ce qui permet aux prestataires de soins de répondre rapidement aux situations d'urgence et d'accélérer le flux de travail de l'imagerie diagnostique.

Il facilite le triage et la priorisation des cas, en particulier dans les établissements de santé où le volume d'images de radiographie thoracique est élevé. La capacité du modèle à identifier rapidement les conditions critiques et les anomalies permet de hiérarchiser efficacement les cas nécessitant une attention immédiate, garantissant ainsi des soins efficaces et opportuns aux patients.

### 2.1.4 Faire progresser la recherche médicale et le développement

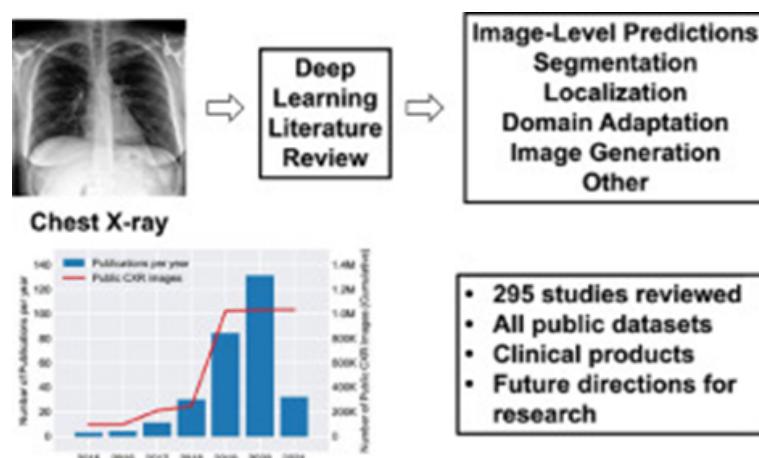


FIGURE 2.2 – Avancement de la recherche médicale

Les réseaux neuronaux convolutionnels profonds (CNN) ont démontré des capacités exceptionnelles dans l'analyse de l'imagerie médicale, y compris l'interprétation des radiographies du thorax. En développant des modèles d'apprentissage profond pour la classification des radiographies du thorax, les chercheurs peuvent contribuer au domaine de la recherche et du développement médical.

Ces modèles permettent l'analyse de données à grande échelle, dévoilant de nouvelles perspectives et des corrélations entre les caractéristiques des images et des maladies spécifiques. Ces connaissances permettent non seulement d'améliorer notre compréhension de diverses affections liées à la poitrine, mais aussi de développer des techniques de diagnostic et des approches thérapeutiques innovantes.

### **2.1.5 Permettre la télémédecine et les soins de santé à distance**

Le développement d'un modèle d'apprentissage profond pour la classification des radiographies thoraciques peut faciliter la télémédecine et les services de soins de santé à distance. Cette technologie permet aux patients de bénéficier de consultations médicales et d'évaluations diagnostiques à distance, éliminant ainsi la nécessité de se rendre sur place.

En s'appuyant sur un système de classification des radiographies thoraciques précis et fiable, les prestataires de soins de santé peuvent évaluer et interpréter les images de radiographies thoraciques à distance, en fournissant des diagnostics et des recommandations de traitement en temps opportun aux patients dans les zones mal desservies ou éloignées.

Cette approche permet de surmonter les barrières géographiques, d'améliorer l'accès aux services de santé et d'améliorer les soins aux patients dans les zones où les infrastructures de santé sont limitées.

### **2.1.6 Améliorer l'enseignement et la formation en radiologie**

Un modèle d'apprentissage profond peut servir d'outil pédagogique pour améliorer l'enseignement et la formation en radiologie.

En fournissant des exemples annotés et un retour d'information en temps réel sur les interprétations des radiographies du thorax, le modèle aide les radiologues et les étudiants en médecine à développer leurs compétences en matière d'identification et de classification des anomalies.

Cette approche d'apprentissage basée sur la technologie améliore l'expérience éducative, promeut une formation standardisée et renforce la compétence des futurs radiologues dans le diagnostic des pathologies thoraciques.

## **2.2 Objectifs du projet**

Les objectifs de ce projet sont les suivants :

- L'objectif principal du projet est de développer une approche basée sur l'apprentissage profond qui utilise un grand ensemble de données d'images CXR pour obtenir des diagnostics précis de cinq maladies thoraciques courantes.

En entraînant le modèle d'apprentissage profond sur une collection complète de centaines de milliers d'images CXR, l'objectif est de permettre au modèle d'apprendre des modèles et des caractéristiques complexes associés à chaque maladie.

Cela conduira finalement à des diagnostics précis et fiables, améliorant l'efficacité de la détection des maladies thoraciques et aidant les professionnels de la santé à fournir un traitement précis et opportun.

- Un autre objectif clé est d'intégrer de manière transparente l'approche basée sur l'apprentissage profond dans le flux de travail clinique existant. Il s'agit de concevoir une interface conviviale qui permette une interaction facile avec le modèle d'apprentissage profond.

L'objectif est de s'assurer que l'approche développée peut être incorporée de manière transparente dans les pratiques quotidiennes des prestataires de soins de santé, en minimisant les perturbations et en facilitant un diagnostic efficace et efficient des maladies thoraciques.

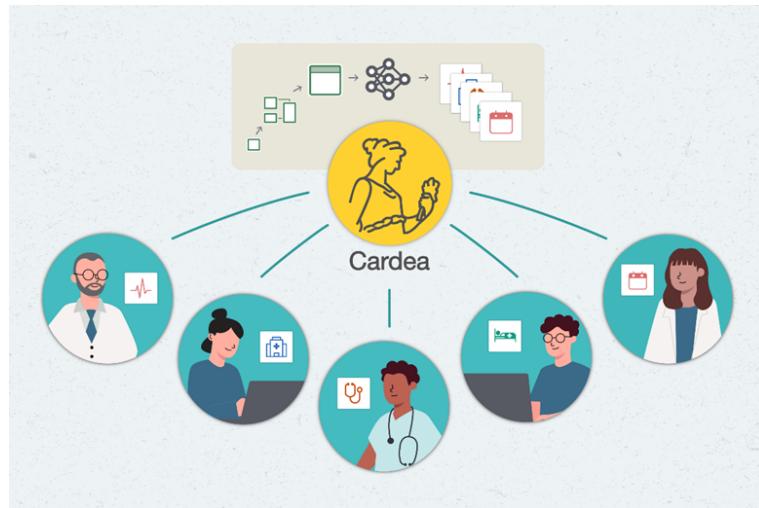


FIGURE 2.3 – Intégration de la solution

- Un objectif important est de viser des performances humaines dans le diagnostic des maladies thoraciques. Bien que les modèles d'apprentissage profond aient montré des capacités exceptionnelles, surpasser la performance humaine reste un défi mais un objectif valable.

En affinant continuellement l'architecture du modèle, les stratégies d'entraînement et les techniques d'optimisation, l'objectif est de repousser les limites de la performance et d'approcher, voire de dépasser, la précision et la fiabilité des radiologues humains.

Atteindre une performance de niveau humain inspirera confiance dans l'approche développée et ouvrira la voie à son adoption généralisée dans les établissements de soins de santé.

## 2.3 Travaux en apport

Dans le domaine de la reconnaissance automatique des maladies pulmonaires, plusieurs études ont examiné les approches basées sur l'apprentissage automatique pour améliorer la détection et la classification des cas de COVID-19, de pneumonie et des cas normaux dans les radiographies du thorax.

Une approche a impliqué l'utilisation d'un préprocesseur basé sur le CNN, qui visait à améliorer dynamiquement les régions pulmonaires pour une détection effi-

cace du COVID-19. L'utilisation de ReCoNet dans les expériences a permis d'obtenir une précision supérieure à 97 % dans la différenciation entre le COVID-19, la pneumonie et les cas normaux.

Un système d'apprentissage profond hybride et multimodal a été proposé, incorporant l'égalisation adaptative des histogrammes limitée par le contraste (CLAHE) et un filtre passe-bande de Butterworth pour améliorer le contraste des images radiographiques et éliminer le bruit.

Cette approche a permis d'obtenir une précision impressionnante de 99,93 %. En outre, les expériences ont montré que les résultats étaient meilleurs lorsque le diaphragme était retiré des échantillons de rayons X, ce qui améliorait encore la précision de la classification.

Les chercheurs ont également proposé une méthode de classification automatique des radiographies thoraciques COVID-19 à l'aide d'un seuil à plusieurs niveaux basé sur l'algorithme d'Otsu et la machine à vecteur de support (SVM). Cette technique a permis de différencier avec précision les cas de COVID-19, de pneumonie et les cas normaux.

Une autre étude s'est concentrée sur l'amélioration des images en augmentant le contraste et a utilisé l'histogramme des gradients orientés pour l'extraction des caractéristiques. Des algorithmes de régression linéaire et de SVM ont ensuite été appliqués pour la classification des rayons X, avec une précision de 96 %.

Ces approches contribuent au corpus de recherche existant sur la reconnaissance automatique des maladies pulmonaires, en mettant en évidence l'efficacité de différentes techniques de prétraitement, telles que l'amélioration de la région dynamique, l'amélioration du contraste, l'élimination du bruit, la suppression du diaphragme et les méthodes d'extraction des caractéristiques.

Ces résultats fournissent des informations précieuses qui éclairent notre propre projet de développement d'une approche précise et fiable basée sur l'apprentissage profond pour la classification des maladies thoraciques en utilisant des techniques et des méthodologies similaires.

## 2.4 Limites

### 2.4.1 Limite 1 : Variabilité de la présentation de la maladie - Défi pour un diagnostic précis des maladies thoraciques

Les maladies thoraciques présentent un large éventail de manifestations, ce qui rend leur présentation complexe et variable. Cette variabilité constitue un défi pour un diagnostic précis à l'aide de modèles d'apprentissage profond. L'efficacité du modèle peut être limitée par la diversité des modèles et des formes de présentation des maladies, ce qui peut entraîner des erreurs de classification ou des faux négatifs.

La variabilité inhérente à la présentation des maladies pose des défis aux modèles d'apprentissage profond en termes de précision et de performance. Pour remédier à cette limitation, des méthodes d'ensemble peuvent être employées.

Ces méthodes consistent à combiner plusieurs modèles ou prédictions pour améliorer la précision du diagnostic et réduire l'impact des erreurs de classification ou des faux négatifs causés par la variabilité de la maladie.

L'intégration de techniques d'ensemble dans le cadre de l'apprentissage profond peut améliorer les performances du modèle et les capacités de diagnostic globales.

#### **2.4.2 Limite 2 : Disponibilité d'un cadre unifié d'apprentissage profond pour la détection de maladies thoraciques multiples.**

Les approches d'apprentissage profond existantes dans le domaine de la classification des maladies thoraciques se concentrent principalement sur des maladies spécifiques telles que la pneumonie, la tuberculose ou le cancer du poumon.

Cependant, la construction d'un cadre unifié d'apprentissage profond capable de détecter avec précision plusieurs maladies thoraciques courantes à partir de radiographies du thorax reste une tâche difficile qui nécessite d'importants efforts de recherche.

La disponibilité limitée de ces cadres complets entrave le développement d'un système de diagnostic robuste et polyvalent.

## **2.5 Contributions**

Notre contribution à l'ensemble des travaux existants sur la classification des maladies thoraciques porte sur trois domaines clés : le lissage des étiquettes, l'amélioration des images et l'apprentissage par transfert à l'aide d'un modèle VGG16.

Tout d'abord, nous appliquons des techniques de lissage des étiquettes pour améliorer la robustesse et la généralisation de notre modèle d'apprentissage profond.

En incorporant la régularisation du lissage des étiquettes, nous introduisons une représentation plus nuancée et plus raffinée des classes cibles, ce qui réduit l'ajustement excessif et améliore les performances du modèle.

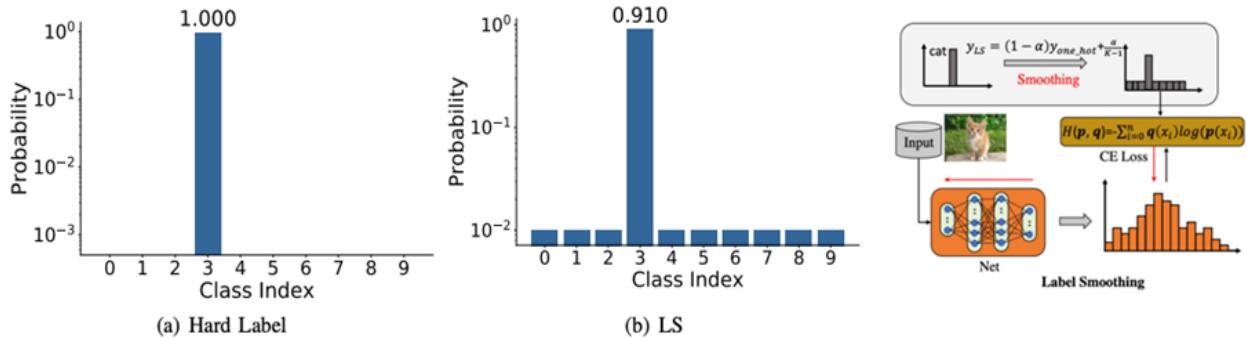


FIGURE 2.4 – Technique du Label smoothing

Le lissage d'étiquette est une technique de régularisation couramment utilisée dans l'apprentissage profond pour améliorer la généralisation et la performance des modèles de classification.

Elle consiste à modifier les étiquettes cibles pendant la formation en introduisant une petite quantité d'incertitude ou de bruit. Au lieu d'attribuer une étiquette dure de 0 ou 1 à chaque classe, le lissage des étiquettes attribue des probabilités adoucies aux étiquettes cibles.

Dans les tâches de classification traditionnelles, l'étiquette cible d'un échantillon est un vecteur à un coup, avec une valeur de 1 pour la vraie classe et de 0 pour les autres classes.

Avec le lissage des étiquettes, l'étiquette cible est modifiée de manière à ce qu'une faible probabilité soit également attribuée aux classes incorrectes.

Par exemple, au lieu d'attribuer une étiquette de [1, 0, 0] à un échantillon appartenant à la classe 1, le lissage d'étiquette peut attribuer une étiquette adoucie de [0,9, 0,05, 0,05], où les probabilités sont réparties entre toutes les classes.

L'objectif du lissage des étiquettes est d'empêcher le modèle de devenir trop confiant dans ses prédictions et de l'encourager à apprendre des représentations plus robustes et généralisées.

En introduisant une petite part d'incertitude dans les étiquettes, le modèle est contraint de prendre en compte les informations provenant de plusieurs classes et d'éviter de s'appuyer uniquement sur les probabilités de chaque classe.

Cela peut contribuer à réduire le surajustement et à améliorer la capacité du modèle à se généraliser à des données inédites.

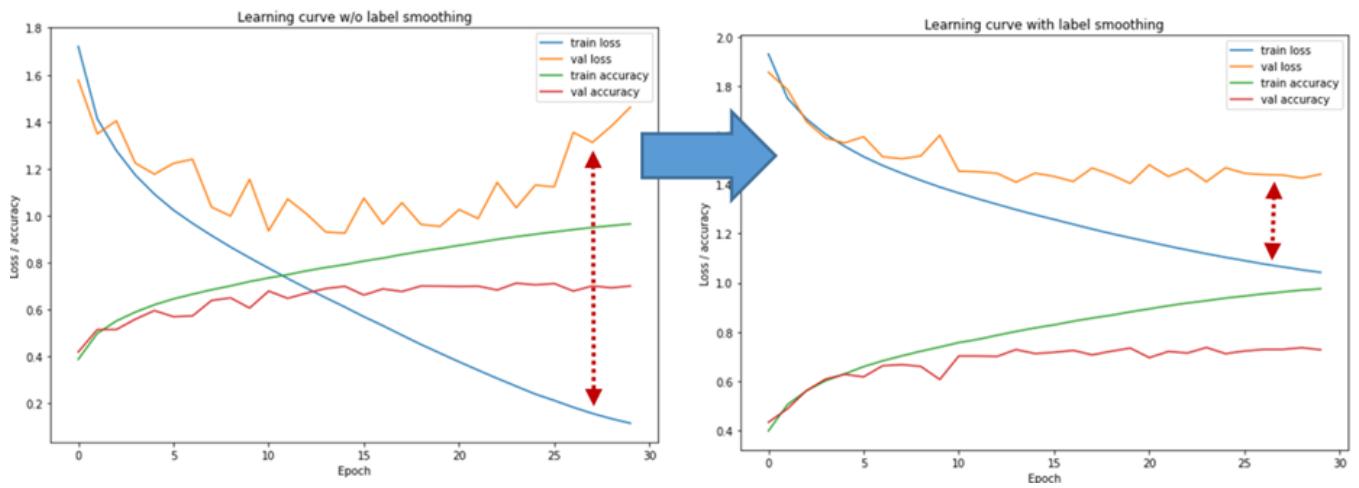


FIGURE 2.5 – Effet du Label smoothing

Le lissage des étiquettes peut être particulièrement utile lorsque l'on travaille avec des données d'apprentissage limitées ou lorsque l'ensemble de données contient des étiquettes bruyantes ou ambiguës, ce qui est le cas dans l'ensemble de données CheXpert.

Il encourage le modèle à apprendre des caractéristiques plus représentatives et discriminantes, ce qui permet d'obtenir de meilleures performances sur les ensembles d'apprentissage et d'évaluation. En outre, le lissage des étiquettes peut contribuer à atténuer l'impact du bruit des étiquettes ou des annotations incorrectes dans les données d'apprentissage, ce qui rend le modèle plus résistant à ces incohérences.

Dans l'ensemble, le lissage des étiquettes est une technique de régularisation efficace qui favorise une meilleure généralisation et de meilleures performances dans les tâches de classification, améliorant ainsi la fiabilité et la robustesse des modèles d'apprentissage profond.

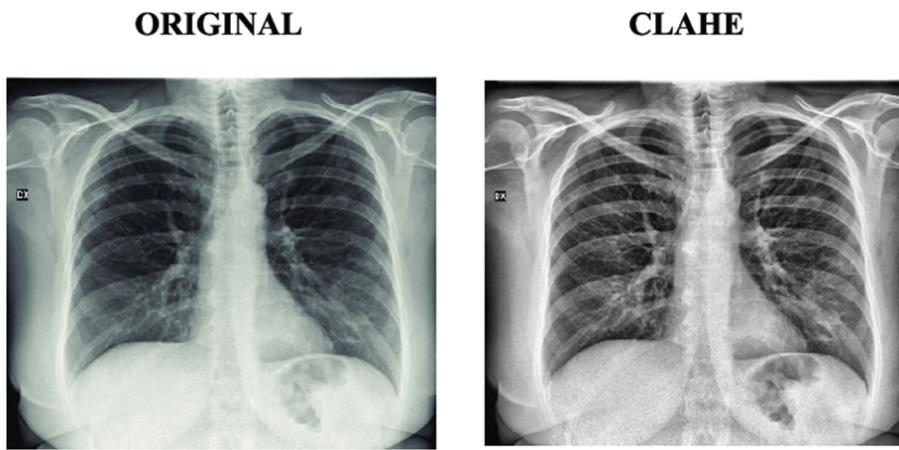


FIGURE 2.6 – Effet de CLAHE

Deuxièmement, nous améliorons la qualité des images de radiographie thoracique grâce à des techniques avancées de traitement d'images. En appliquant des

méthodes telles que l'égalisation d'histogramme adaptative limitée au contraste (CLAHE), nous améliorons efficacement la visibilité des caractéristiques et des détails importants dans les images.

Cette étape de prétraitement améliore la capacité du modèle à extraire des informations pertinentes et à faire des prédictions précises.

Enfin, nous tirons parti de l'apprentissage par transfert en utilisant un modèle VGG16 pré-entraîné sur un vaste ensemble de données composé d'images COVID-19 et d'images de pneumonie.

En affinant ce modèle, nous adaptons les caractéristiques apprises à nos tâches spécifiques de classification des maladies thoraciques.

Cette approche d'apprentissage par transfert nous permet d'exploiter les connaissances et les représentations apprises à partir d'un vaste ensemble de données, d'améliorer les performances du modèle et de permettre un diagnostic plus précis et plus efficace des maladies thoraciques courantes.

Le lissage des étiquettes et l'amélioration des images à l'aide de CLAHE, notre approche intègre également l'agrégation des résultats de cinq modèles différents, y compris le modèle VGG16 finement ajusté. L'agrégation, ou apprentissage d'ensemble, est une technique qui combine les prédictions de plusieurs modèles pour prendre une décision finale.

En combinant les résultats de plusieurs modèles, nous visons à tirer parti des forces et de la diversité de chaque modèle individuel, afin d'améliorer les performances globales et la robustesse de notre système.

Chaque modèle peut avoir appris différentes représentations ou capturé différents aspects des données, et l'agrégation nous permet de bénéficier de leur intelligence collective.

Le processus d'agrégation consiste à prendre les prédictions de chaque modèle et à les agréger à l'aide de diverses techniques telles que le vote majoritaire, la moyenne pondérée ou l'empilement. Cela permet de réduire l'impact des biais ou des erreurs des modèles individuels et d'obtenir une prédition finale plus fiable et plus précise.

En agrégeant les résultats de plusieurs modèles, y compris le modèle VGG16 affiné, nous visons à améliorer les performances globales de notre système d'apprentissage profond pour la classification des radiographies du thorax.

La combinaison du lissage des étiquettes, de l'amélioration des images et de l'agrégation des modèles nous permet de tirer parti des avantages de chaque technique, ce qui se traduit par une solution plus robuste et plus efficace pour diagnostiquer avec précision les maladies thoraciques courantes à partir d'images CXR.

## 2.6 Conclusion

En conclusion, ce chapitre a donné un aperçu des spécifications du projet, y compris le contexte, les objectifs, la portée et les limites. Nous avons discuté de nos contributions, telles que le lissage des étiquettes et les techniques d'amélioration de l'image. Le chapitre suivant, intitulé "Méthodologie et mise en œuvre", entrera dans les détails techniques. Il couvrira la collecte des données, le prétraitement, l'amélioration des images, le modèle de prédiction des maladies, l'évaluation, le déploiement et conclura par une discussion des résultats et des améliorations potentielles.

# 3 | Méthodologie et Implementation

## 3.1 Collecte des données et prétraitement

### 3.1.1 Collecte des Données via Kaggle

Kaggle est une plateforme en ligne pour les scientifiques des données qui permet de partager des ensembles de données, des notebooks et des compétitions. Bien que Kaggle ne soit pas une source directe de données, il existe une dataset sur Kaggle qui représente une partie de Chexpert dataset

### 3.1.2 Prétraitement

Les performances du réseau neuronal profond sur les CXR bruts peuvent être affectées par des zones bruyantes non pertinentes telles que les textes ou l'existence d'irrégularités notamment au niveau des bordures . En outre, nous observons un taux élevé de CXR dont l'alignement est médiocre. Ainsi une série d'étapes de prétraitement afin de réduire l'effet des facteurs non pertinents et de se concentrer sur l'alignement des poumons.

### 3.1.3 Redimensionnement des images

Le redimensionnement des images est une étape importante dans l'utilisation d'images dans les modèles de Deep Learning vu qu'ils prennent souvent en entrée des images de taille fixe. Il est donc souvent nécessaire de redimensionner les images avant de les utiliser dans ces modèles. Dans notre projet on a redimensionné les images satellites ainsi que leurs masques avec un largeur  $L=256$  et une hauteur  $H=256$  grâce à la bibliothèque cv2

### 3.1.4 Normalisation de l'image

La normalisation des images est une étape primordiale du prétraitement des données en Deep Learning. Elle consiste à ajuster les pixels des images de manière à ce qu'ils aient une distribution de probabilité plus uniforme. La normalisation peut être effectuée de différentes manières, mais la méthode la plus courante consiste à diviser les pixels par 255 pour qu'ils soient dans l'intervalle  $[0,1]$  ce qui assure une amélioration de la performance du modèle.

### 3.1.5 Division de l'ensemble de Données en deux parties distinctes

L'ensemble de données se divise en deux sous-ensembles, dont le premier 90% est utilisé pour entraîner un modèle d'apprentissage automatique et le second 10% pour évaluer la performance de ce modèle sur des données jamais vues auparavant.

## 3.2 Techniques d'amélioration employées

### 3.2.1 Filtre de gabor

A. Implémentation :

Afin d'exploiter ce filtre générique on a créé un filtre bank dont le but est effectuer une analyse multi-échelle d'une image en entrée.

Pour construire une banque de filtres à partir du filtre de Gabor, on utilise des filtres de Gabor avec différentes fréquences et orientations

```

for theta in range(2): # Define number of thetas. Here only 2 theta values 0 and 1/4 . pi
    theta = theta / 4. * np.pi
    for sigma in (1, 3): # Sigma with values of 1 and 3
        for lamda in np.arange(0, np.pi, np.pi / 4): # Range of wavelengths
            for gamma in (0.05, 0.5): # Gamma values of 0.05 and 0.5
                gabor_label = 'Gabor' + str(num)
                kernel = cv.getGaborKernel((5, 5), sigma, theta, lamda, gamma, phi, ktype=cv.CV_32F)
                kernels.append(kernel)
                fimg = cv.filter2D(img, cv.CV_8UC3, kernel)
                filtered_img = img.reshape(-1)
                df[gabor_label] = filtered_img
                num += 1
print(df.head())
df.to_csv('Gabor.csv')
    
```

FIGURE 3.1 – Code source du banque de filtre

Lorsque l'image est passée à travers la banque de filtres de Gabor, chaque filtre génère une réponse qui met en évidence les caractéristiques ou features présentés dans ce type du signal à une certaine échelle et orientation. Cette combinaison des réponses constitue une représentation multi-échelle du signal comme indique la figure et qui sera par la suite alimenté au algorithme d'apprentissage.

|   | Original | Pixels | Gabor1 | Gabor2  | Gabor3  | Gabor4  | Gabor5  | Gabor6  | Gabor7  | \ |
|---|----------|--------|--------|---------|---------|---------|---------|---------|---------|---|
| 0 |          | 134    | 134    | 134     | 134     | 134     | 134     | 134     | 134     |   |
| 1 |          | 134    | 134    | 134     | 134     | 134     | 134     | 134     | 134     |   |
| 2 |          | 135    | 135    | 135     | 135     | 135     | 135     | 135     | 135     |   |
| 3 |          | 135    | 135    | 135     | 135     | 135     | 135     | 135     | 135     |   |
| 4 |          | 136    | 136    | 136     | 136     | 136     | 136     | 136     | 136     |   |
|   | Gabor8   | Gabor9 | ...    | Gabor23 | Gabor24 | Gabor25 | Gabor26 | Gabor27 | Gabor28 | \ |
| 0 | 134      | 134    | ...    | 134     | 134     | 134     | 134     | 134     | 134     |   |
| 1 | 134      | 134    | ...    | 134     | 134     | 134     | 134     | 134     | 134     |   |
| 2 | 135      | 135    | ...    | 135     | 135     | 135     | 135     | 135     | 135     |   |
| 3 | 135      | 135    | ...    | 135     | 135     | 135     | 135     | 135     | 135     |   |
| 4 | 136      | 136    | ...    | 136     | 136     | 136     | 136     | 136     | 136     |   |

FIGURE 3.2 – Extrait de la banque de filtre sous forme d'un fichier csv

## B. Test :

Ce filtre nous a donné des mauvais résultats environ précision=70% vu qu'il est difficile à gérer et nécessite plusieurs réponses empiriques (peu courtes) pour aboutir aux meilleurs paramètres du filtre .

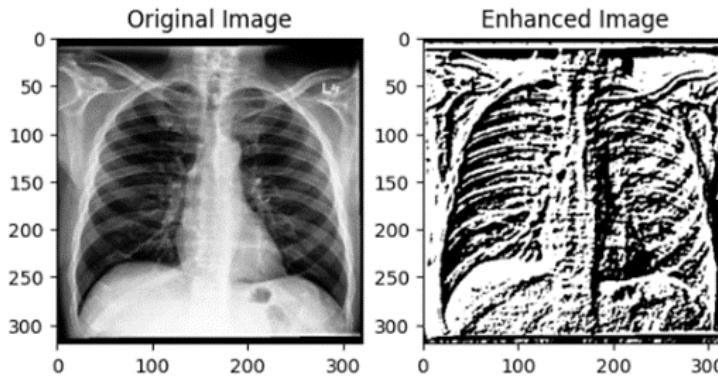


FIGURE 3.3 – Image améliorée pour certaines valeurs de paramètres du filtre

### 3.2.2 Préprocesseur multi-niveaux basé sur le CNN

Inspiré par le concept de design du module RemNet de génération d'images résiduelles , un réseau particulièrement efficace pour identifier les modèles de caméras à partir des empreintes digitales cachées dans les images d'entrée. Notre proposition consiste à utiliser un module dynamique similaire au module d'inception pour soustraire les activations extraites et améliorer les caractéristiques désirées d'une image radiographique donnée.

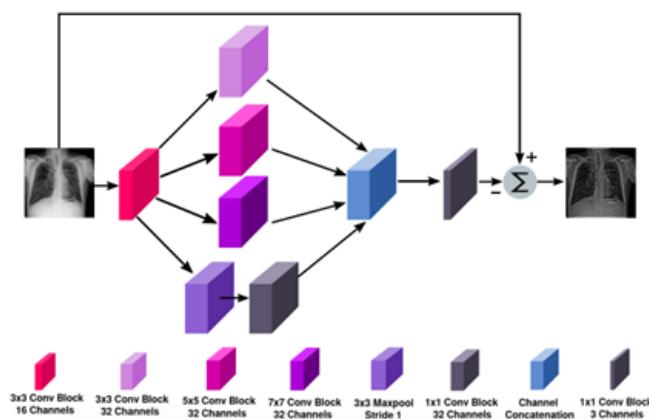


FIGURE 3.4 – Représentation schématique du bloc préprocesseur

```

def inception_block(x, filters):
    branch1 = Conv2D(filters[0], (3, 3), padding='same', activation='relu')(x)
    branch2 = Conv2D(filters[1], (3, 3), padding='same', activation='relu')(branch1)
    branch3 = Conv2D(filters[2], (5, 5), padding='same', activation='relu')(branch1)
    branch4 = Conv2D(filters[3], (7, 7), padding='same', activation='relu')(branch1)
    branch_pool = MaxPooling2D((3, 3), strides=(1, 1), padding='same')(branch1)
    branch5 = Conv2D(filters[4], (1, 1), padding='same', activation='relu')(branch_pool)

    concatenation = Concatenate(axis=-1)([branch2, branch3, branch4, branch5])
    output = Conv2D(filters[5], (3, 3), padding='same', activation='relu')(concatenation)

    return output
    
```

(a) Code source

|   | Layer         | Output Size    | Parameters              |
|---|---------------|----------------|-------------------------|
| A | 3 x 3 Conv    | 256 x 256 x 16 | F=16, K=3 x 3, S=1, P=1 |
|   | 3 x 3 Conv    | 256 x 256 x 32 | F=32, K=3 x 3, S=1, P=1 |
|   | 5 x 5 Conv    | 256 x 256 x 32 | F=32, K=7 x 7, S=1, P=2 |
|   | 7 x 7 Conv    | 256 x 256 x 32 | F=32, K=7 x 7, S=1, P=3 |
|   | 3 x 3 Maxpool | 256 x 256 x 16 | K=3 x 3, S=1, P=1       |
|   | 1 x 1 Conv    | 256 x 256 x 32 | F=32, K=1 x 1, S=1      |
|   | 1 x 1 Conv    | 256 x 256 x 3  | F=3, K=1 x 1, S=1       |

(b) Table détaillée de l'architecture

FIGURE 3.5 – Architecture du modèle

- Inconvénient : cette méthode ajoute 2982 paramètres à apprendre lors de l'entraînement + les paramètres à hypertuning d'où l'augmentation des couts processeur.

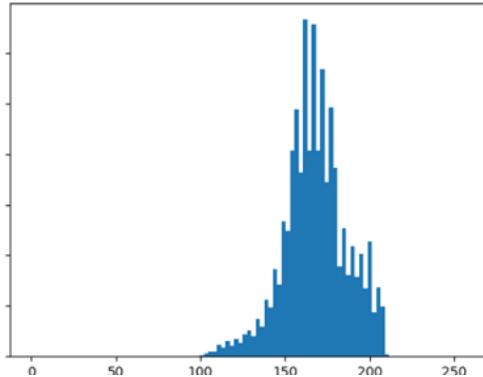
### 3.2.3 CLAHE

```

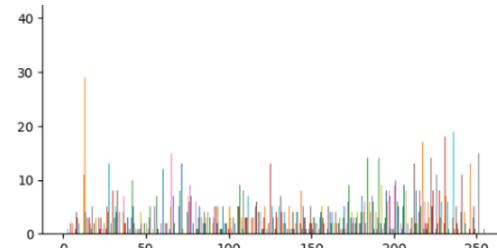
clahe = cv.createCLAHE(clipLimit=3.0 , tileGridSize=(8,8))
clahe_img = clahe.apply(l)

plt.hist(clahe_img,bins=100,range=(0,255))
plt.show()
    
```

FIGURE 3.6 – Code source du CLAHE



(a) Histogramme de l'image avant l'opération



(b) Histogramme de l'image après l'opération

FIGURE 3.7 – Analyse histogramme

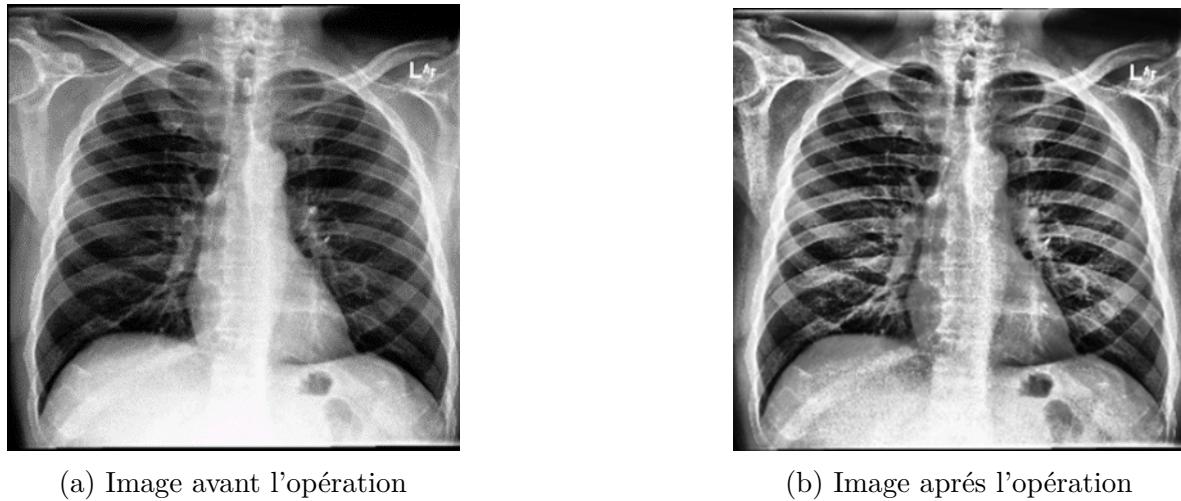


FIGURE 3.8 – Résultat de l'image amélioré démontrant l'extraction ses caractéristiques

### 3.3 Modèle de prédition de la maladie

En imagerie médicale, comme les données de radiographie thoracique, les diagnostics et les observations sont souvent organisés en structures hiérarchiques connues sous le nom d'arbres ou de graphes acycliques dirigés (DAG).

Ces hiérarchies sont construites par des experts du domaine, généralement des radiologues, qui possèdent des connaissances et une expertise approfondies dans le domaine. L'organisation hiérarchique des étiquettes permet une représentation plus complète et plus structurée des relations entre les différents diagnostics et observations.

Dans le contexte des radiographies du thorax, une hiérarchie d'étiquettes pourrait être constituée d'étiquettes parentales représentant des catégories de maladies plus larges, telles que les "maladies pulmonaires", les "maladies cardiovasculaires" ou les "infections". Ces étiquettes parentales servent de groupements de niveau supérieur qui englobent plusieurs maladies ou affections spécifiques. Les étiquettes enfants, quant à elles, représentent des diagnostics ou des observations plus spécifiques au sein de chaque catégorie parentale, comme "Pneumonie", "Épanchement pleural" ou "Masse pulmonaire".



FIGURE 3.9 – Graphes acycliques dirigés (DAG)

Dans le contexte des radiographies du thorax, une hiérarchie d'étiquettes pourrait consister en des étiquettes parentales représentant des catégories de maladies

plus larges, telles que "Maladie pulmonaire", "Maladie cardiovasculaire" ou "Infection".

Ces étiquettes parentales servent de groupements de niveau supérieur qui englobent plusieurs maladies ou affections spécifiques. Les étiquettes enfants, quant à elles, représentent des diagnostics ou des observations plus spécifiques au sein de chaque catégorie parentale, comme "Pneumonie", "Épanchement pleural" ou "Masse pulmonaire".

Cette approche hiérarchique facilite également l'interprétation des résultats du modèle, car elle s'aligne sur la nature structurée des diagnostics et des observations médicales.

Dans le cadre de notre projet, nous exploiterons la structure hiérarchique des étiquettes dans l'ensemble de données Chest X-Ray pour améliorer le modèle de prédiction des maladies. En prenant en compte les étiquettes parentales et les étiquettes enfant lors de la formation et de l'inférence, notre modèle sera capable de capturer les relations hiérarchiques et les dépendances entre les différentes maladies thoraciques.

Cette approche contribuera à des prédictions plus précises et contextuelles, permettant aux professionnels de la santé d'obtenir une compréhension globale de l'état du patient et d'orienter les décisions thérapeutiques appropriées.

En outre, l'organisation hiérarchique des étiquettes offre une évolutivité et une flexibilité dans l'extension des capacités du modèle. Au fur et à mesure que de nouvelles maladies ou observations sont identifiées et ajoutées à la hiérarchie des étiquettes, notre modèle peut facilement les intégrer dans le cadre existant.

Cela permet un apprentissage continu et une adaptation à l'évolution des connaissances médicales, garantissant que le modèle reste à jour et capable de diagnostiquer avec précision un large éventail de maladies thoraciques.

Compte tenu de la nature hiérarchique des étiquettes en imagerie médicale, il est crucial d'incorporer cette structure dans l'apprentissage et la prédiction du modèle. De nombreuses approches existantes pour la classification des radiographies thoraciques traitent chaque étiquette de manière indépendante, sans tenir compte des interdépendances entre les maladies. Ces méthodes, connues sous le nom de modèles de classification plats, ont des limites dans la modélisation des relations hiérarchiques.

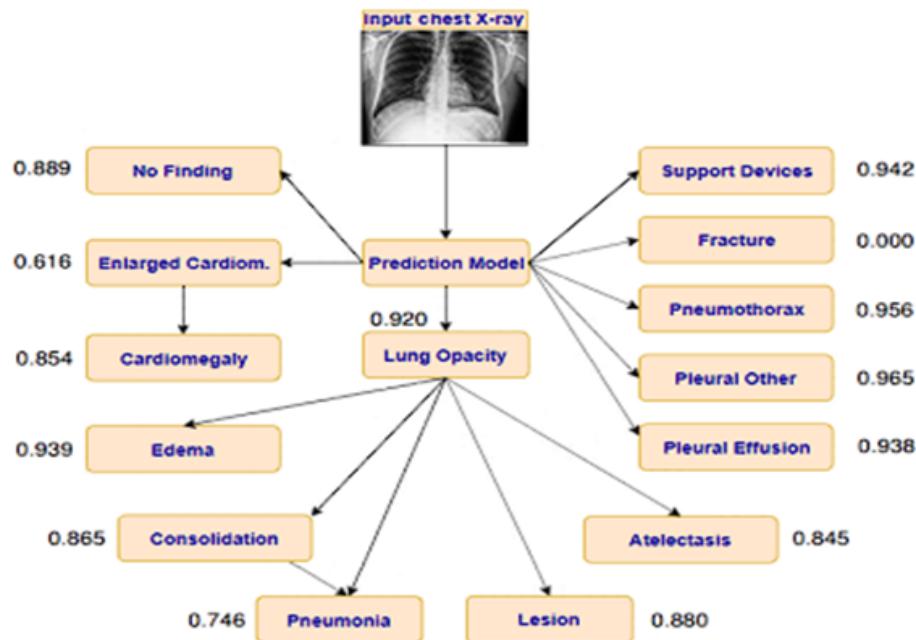


FIGURE 3.10 – Model hiérarchique

Par exemple, la figure 1 illustre comment la présence d'une cardiomégalie implique la présence d'une hypertrophie du cardio-médiastin. En outre, les étiquettes des niveaux inférieurs, en particulier les noeuds des feuilles, ont souvent un nombre limité d'échantillons positifs, ce qui entraîne un biais dans les modèles d'apprentissage à plat en faveur de la classe négative.

Par conséquent, il est essentiel de tirer parti de la structure des étiquettes et de remédier aux limites des modèles d'apprentissage à plat pour obtenir une classification précise et complète des radiographies du thorax.

Pour remédier à ce problème, l'architecture multi-hiéroglyphique que nous proposons exploite les relations hiérarchiques entre les étiquettes pour faire des prédictions.

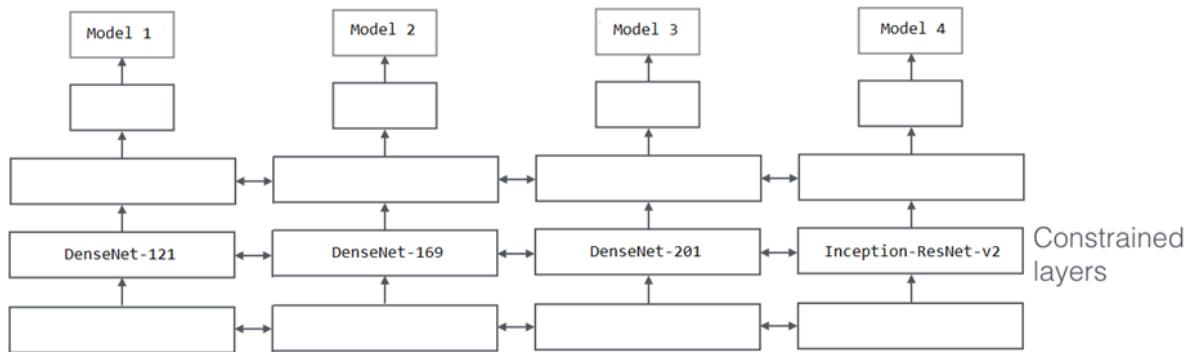


FIGURE 3.11 – L'architecture du model

Dans notre approche, nous avons exploité les modèles pré-entraînés de DenseNet-

121, DenseNet-169, DenseNet-201 et Inception-ResNet-v2, qui ont déjà été entraînés sur un ensemble de données à grande échelle pour la classification des maladies thoraciques. Ces modèles ont démontré leur efficacité à capturer des modèles et des caractéristiques complexes dans les images radiographiques du thorax.

Les poids pré-entraînés de ces modèles ont été chargés dans notre système, ce qui nous a permis d'exploiter les représentations apprises à partir d'un ensemble de données à grande échelle. Le pré-entraînement sur un grand ensemble de données permet aux modèles de capturer des caractéristiques et des connaissances générales qui peuvent être affinées pour notre tâche de classification spécifique.

Le modèle VGG16 a joué un rôle crucial dans notre approche de la classification des maladies thoraciques. Nous avons utilisé le modèle VGG16 de l'article ReCoNet, qui a été conçu à l'origine pour la classification de COVID-19 et de la pneumonie. L'architecture VGG16 est un réseau neuronal convolutionnel profond connu pour sa simplicité et son efficacité.

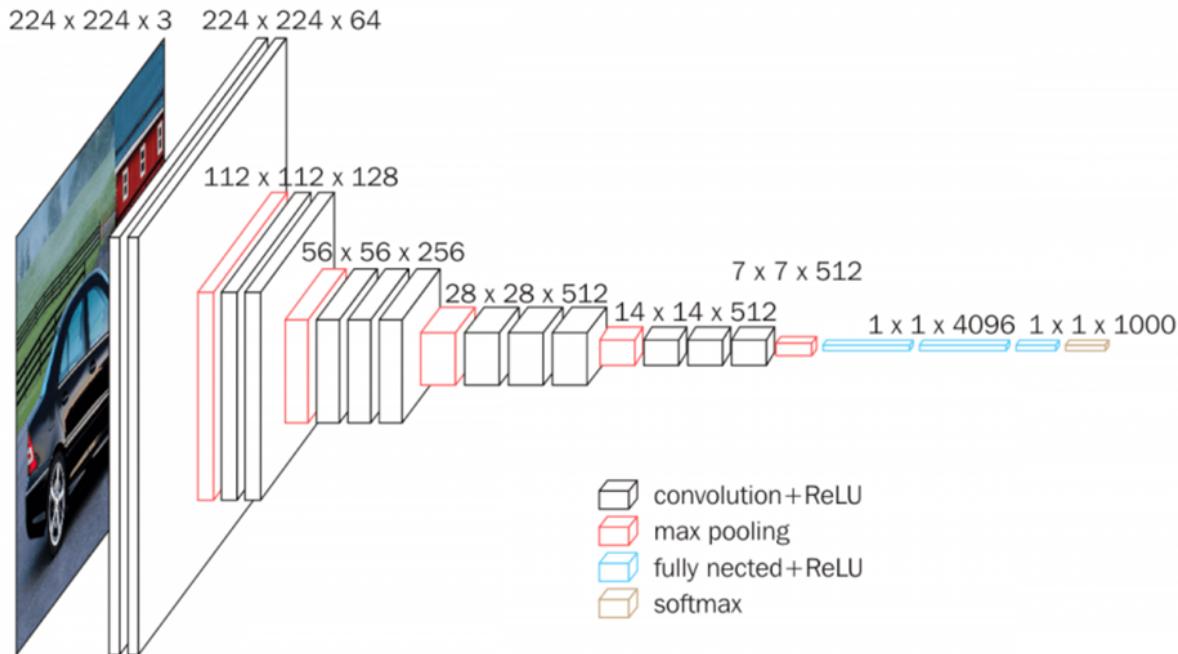


FIGURE 3.12 – L'architecture du modèle VGG16

Pour adapter le modèle VGG16 à notre tâche spécifique, nous avons chargé ses poids pré-entraînés, qui ont été initialement entraînés sur un grand ensemble de données d'images COVID-19 et de pneumonie.

Ce pré-entraînement a permis au modèle VGG16 d'acquérir des connaissances précieuses et d'apprendre des représentations de maladies thoraciques similaires.

Après le chargement des poids pré-entraînés, nous avons introduit un nouveau bloc de prétraitement dans le modèle VGG16. Ce bloc de prétraitement comprend une égalisation d'histogramme adaptative limitée au contraste (CLAHE) en tant que technique d'amélioration de l'image.

En appliquant la CLAHE, nous avons amélioré la visibilité des caractéristiques et des détails importants dans les images de radiographie thoracique. Cette étape de prétraitement visait à améliorer la capacité du modèle à extraire des informations pertinentes et à faire des prédictions précises.

La combinaison des poids pré-entraînés de l'article ReCoNet et l'ajout du bloc de préprocesseur CLAHE nous ont permis d'affiner le modèle VGG16 spécifiquement pour notre tâche de classification à cinq étiquettes.

La mise au point a impliqué l'entraînement du modèle sur notre ensemble de données cible, ce qui lui a permis d'adapter ses caractéristiques et représentations apprises afin de mieux prédire des maladies thoraciques similaires.

En incorporant le modèle VGG16 dans notre approche, nous avons enrichi la diversité des modèles et tiré parti de ses connaissances spécialisées dans la classification de COVID-19 et de la pneumonie.

L'agrégation des résultats des quatre modèles initiaux et du modèle VGG16 nous a permis de bénéficier de leur intelligence collective, ce qui s'est traduit par une prédiction plus précise et plus complète des maladies thoraciques.

Afin d'obtenir une prédiction non biaisée pour le problème de classification à cinq étiquettes, les résultats de ces quatre modèles initiaux ont été agrégés.

Ce processus d'agrégation combine les prédictions individuelles de chaque modèle pour créer une prédiction finale qui bénéficie des diverses perspectives et forces des modèles. En agrégeant les résultats, nous pouvons faire des prédictions plus robustes et plus précises en tenant compte de plusieurs points de vue.

En outre, pour renforcer le réalisme et envisager toutes les possibilités pendant l'inférence, nous avons utilisé le lissage des étiquettes.

Le lissage des étiquettes introduit une petite part d'incertitude dans les étiquettes cibles, empêchant le modèle de devenir trop confiant dans ses prédictions et l'encourageant à prendre en compte les informations provenant de plusieurs catégories de maladies.

Cette technique de régularisation favorise des prédictions plus réalistes et aide le modèle à mieux se généraliser à des données inédites.

## 3.4 Evaluation

Pour évaluer les performances de la méthode proposée, nous avons effectué des évaluations sur un ensemble de test caché de CheXpert, composé de 500 radiographies du thorax (CXR) qui ont été indépendamment étiquetées par 8 radiologues certifiés par le conseil d'administration.

Sur ces 8 radiologues, les annotations de 3 d'entre eux ont été utilisées pour comparer les performances des radiologues individuels. Le vote majoritaire des 5

radiologues restants a été considéré comme la vérité de base pour la comparaison.

Pour chacun des 3 radiologues, nous avons calculé les scores de l'aire sous la courbe (AUC) par rapport à la vérité de base pour les cinq maladies sélectionnées : Atelectasie, cardiomégalie, consolidation, œdème et épanchement pleural.

Ces scores AUC ont servi de mesure pour évaluer la performance des radiologues dans la classification précise de la présence ou de l'absence de ces maladies.

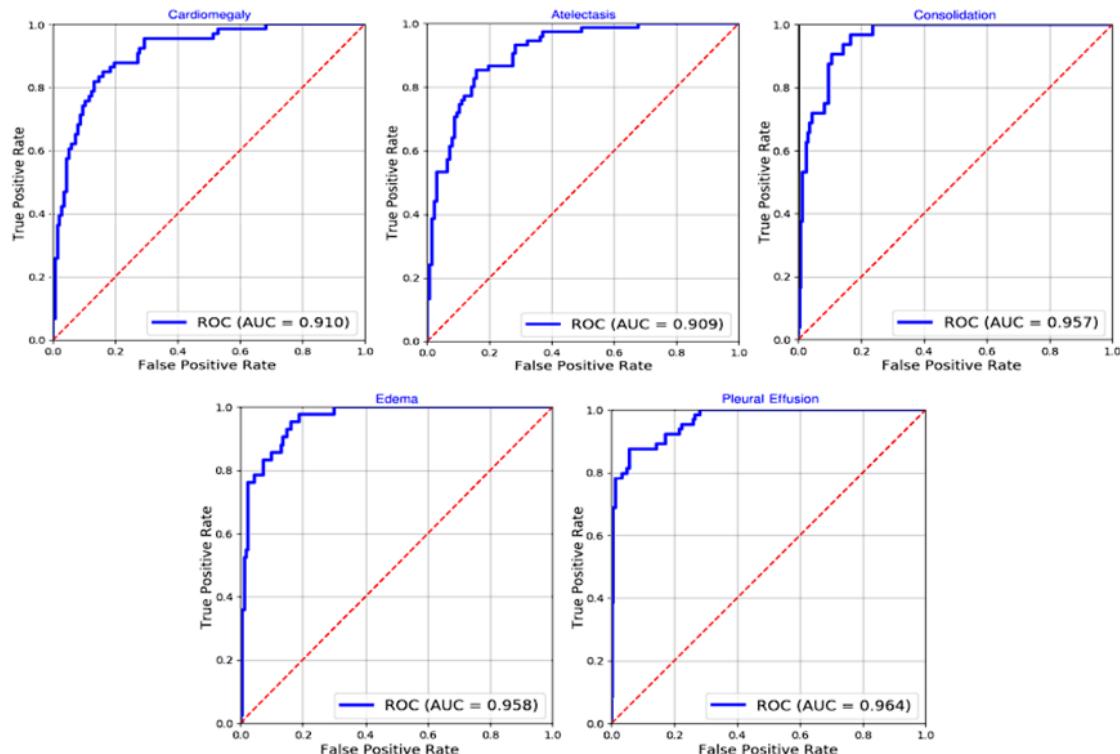


FIGURE 3.13 – Résultats obtenus

En comparant les scores AUC obtenus par la méthode proposée avec ceux des radiologues individuels, nous pouvons déterminer l'efficacité et la fiabilité de la méthode proposée dans la classification des maladies thoraciques.

Cette approche d'évaluation permet une évaluation complète de la performance des experts humains et de la méthode proposée, fournissant des informations précieuses sur les capacités de diagnostic et les avantages potentiels de l'approche basée sur l'apprentissage profond développée.

## 3.5 Discussion

En exploitant un ensemble de données à grande échelle et en entraînant un ensemble de CNN robustes, nous avons développé un modèle d'apprentissage profond capable de prédire avec précision plusieurs maladies thoraciques à partir de radiographies du thorax (CXR).

Nos résultats empiriques ont démontré des améliorations significatives, mesurées par l'aire sous la courbe (AUC), en prenant en compte les interdépendances entre les maladies et en appliquant un lissage des étiquettes aux échantillons incertains.

Nous avons observé qu'il est particulièrement difficile d'obtenir des scores AUC élevés pour toutes les maladies en utilisant un seul CNN. Les performances de la classification varient en fonction de facteurs tels que les architectures de réseau, la distribution des échantillons positifs et négatifs et les caractéristiques visuelles des maladies pulmonaires détectées.

Dans de tels cas, l'utilisation d'un ensemble de plusieurs modèles d'apprentissage profond devient cruciale pour renforcer les capacités de généralisation du modèle final et améliorer ses performances globales.

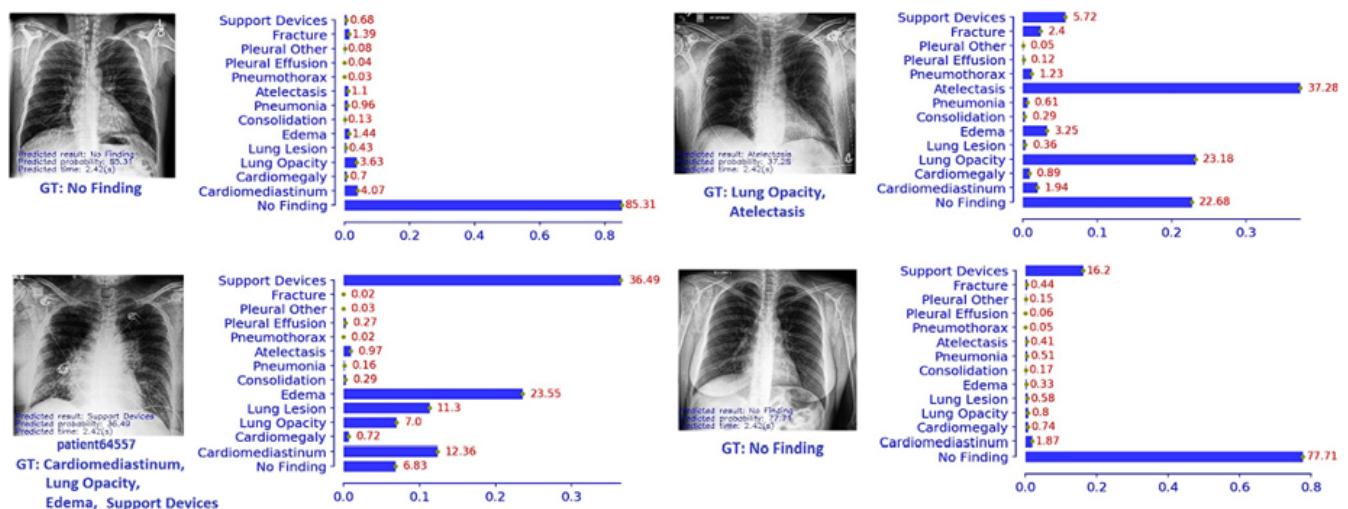


FIGURE 3.14 – Généralisation du modèle

Le score obtenu pour l'aire sous la courbe (AUC) sert à valider la capacité de généralisation de notre modèle d'apprentissage profond entraîné sur des ensembles de données inédits. De plus, le nombre significatif de radiologues tombant sous les courbes ROC démontre que notre méthode proposée a la capacité d'égaler les performances des experts humains. Ce résultat marque une étape cruciale dans l'application potentielle de notre approche dans des scénarios du monde réel.

## 3.6 Déploiement du modèle

### 3.6.1 Architecture de l'interface graphique :

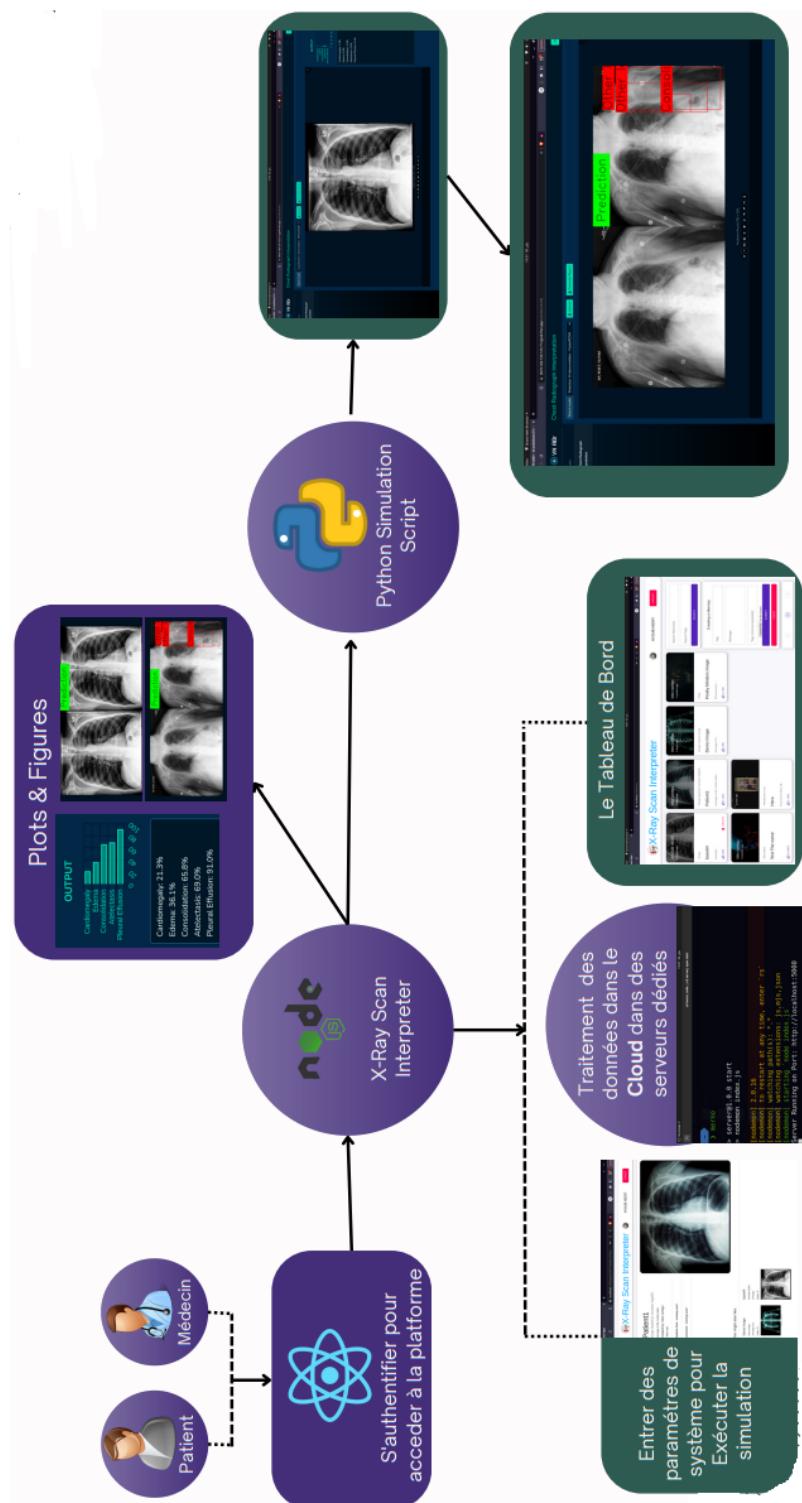


FIGURE 3.15 – Diagramme explicatif de l'interface

### 3.6.2 Etude de cas :

Nous avons deux types d'utilisateurs :

- un utilisateur simple : le patient
- le médecin

1. Ces deux utilisateurs peuvent s'inscrire (avec leur compte Gmail, ou créer un compte sur notre plateforme) afin d'accéder au contenu des cartes publiées en détail. Le patient peut partager son contenu et ses images scannées avec son médecin ou d'autres utilisateurs .

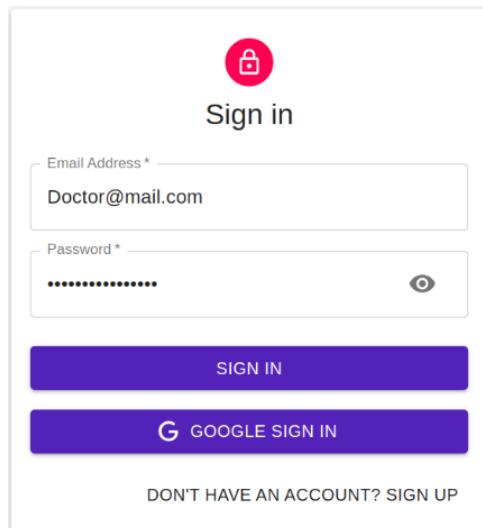


FIGURE 3.16 – Inscription d'un patient

2. Après avoir créé une carte, inséré les détails et téléchargé les images radiologiques scannées, cette carte sera sauvegardée dans la base de données dans le nuage (MongoDB), de sorte que l'utilisateur puisse y accéder quand et où il le souhaite, ainsi que son médecin.

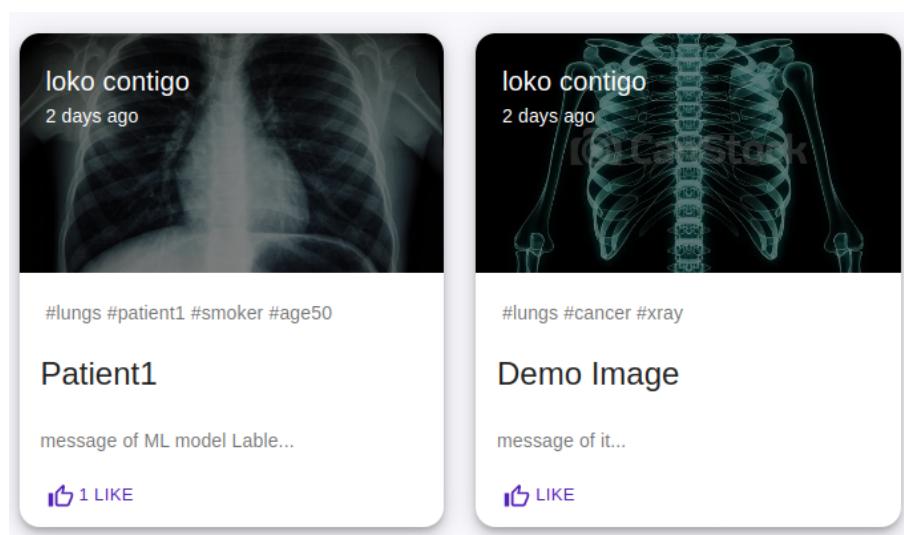


FIGURE 3.17 – Carte d'un patient

3. Après avoir stocké la carte, elle sera affichée dans le tableau de bord. Après avoir cliqué dessus, toutes les informations supplémentaires concernant les cartes connexes seront affichées, un bouton sera affiché pour rediriger l'utilisateur vers l'interface utilisateur Web du traitement des images médicales afin d'appliquer certaines opérations conseillées et d'interagir directement avec les modèles ML ou de générer des rapports médicaux (cette partie concernerait davantage le médecin que l'utilisateur ordinaire en raison des connaissances préalables requises).

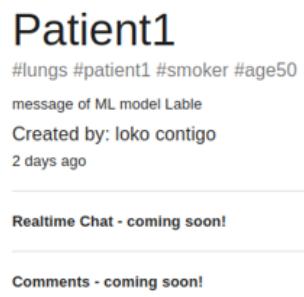


FIGURE 3.18 – Coordonnées d'un patient

4. Sur la base des résultats de l'analyse et des prédictions affichées, le médecin peut prendre sa décision finale ou déléguer le cas à des investigations plus poussées.

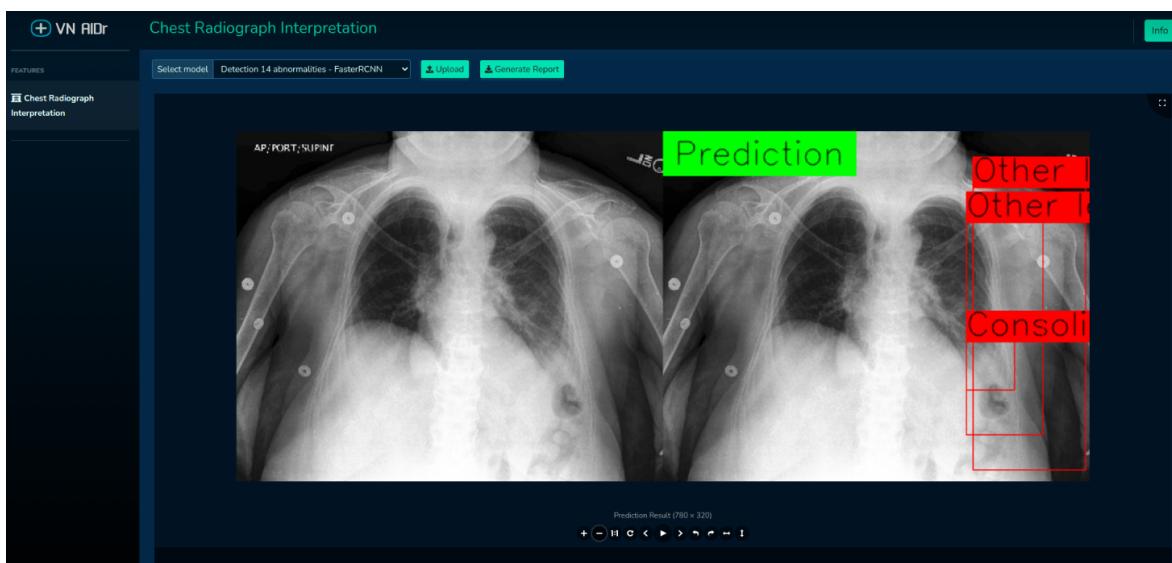


FIGURE 3.19 – Vue globale de l'interface

## 3.7 Conclusion

Dans cet article, nous présentons une approche globale pour la création d'un système de diagnostic assisté par ordinateur de haute précision pour la classification des maladies thoraciques courantes à l'aide de CXR. Presque tous les aspects de la tâche ont été étudiés par nous, y compris le nettoyage des données, la conception du réseau, l'entraînement et l'assemblage.

En particulier, nous avons introduit une nouvelle méthode de lissage d'étiquettes qui permet de résoudre les problèmes de confiance ou d'ajustement excessif qui peuvent survenir lorsque le modèle attribue des probabilités élevées à des prédictions incorrectes ou incertaines.

# Conclusion générale

En conclusion, cet article présente une approche globale pour le développement d'un système de diagnostic assisté par ordinateur très précis pour la classification des maladies thoraciques courantes à l'aide des radiographies thoraciques (CXR). Nous avons examiné en profondeur différents aspects de cette tâche complexe, notamment le nettoyage des données, la conception du réseau, la formation et l'assemblage des modèles. Notre nouvelle procédure de formation, qui exploite efficacement les dépendances entre les maladies et les étiquettes d'incertitude, a permis d'améliorer les performances des réseaux neuronaux convolutifs (CNN).

Un résultat remarquable de notre étude est que notre algorithme d'apprentissage profond a démontré des performances comparables à celles des spécialistes médicaux lors d'un test indépendant. Cela souligne l'efficacité de notre approche et son potentiel à être utilisée comme un outil de soutien précieux pour les professionnels de la santé dans la détection et la classification des maladies thoraciques à partir des radiographies.

Pour l'avenir, nous identifions une direction prometteuse consistant à augmenter la taille et la qualité de l'ensemble de données utilisé dans l'entraînement du modèle. En intégrant un ensemble de données plus vaste et soigneusement annoté, les CNN peuvent améliorer leur capacité de généralisation et réduire leur dépendance à l'égard de l'apprentissage par transfert à partir d'autres domaines. L'inclusion de données supplémentaires provenant de sources telles que MIMIC-CXR pourrait encore améliorer les performances de notre système de diagnostic.

De plus, nous sommes convaincus que la collaboration entre les systèmes de diagnostic médical basés sur l'apprentissage automatique et les radiologues peut apporter des améliorations significatives dans le domaine du diagnostic des maladies thoraciques. En combinant l'expertise des radiologues avec la puissance de l'apprentissage profond, nous pouvons améliorer la précision, la rapidité et la fiabilité des diagnostics, ce qui bénéficie à la fois aux professionnels de la santé et aux patients.

En conclusion, ce projet de recherche a démontré l'utilité et l'efficacité de l'apprentissage profond dans l'analyse des images médicales pour le diagnostic des maladies thoraciques. Malgré les défis et les limitations rencontrés, nous avons réussi à développer un système prometteur. Il est essentiel de continuer à explorer et à développer des approches basées sur l'apprentissage profond pour améliorer la précision et l'efficacité des diagnostics médicaux.

## 4 | Bibliographie

- [1] N. England, Diagnostic imaging dataset statistical release. February 2019,
- [2] L. Anderson, A. Dean, D. Falzon, K. Floyd, I. Baena, C. Gilpin, P. Glaziou, Y. Hamada, T. Hiatt, A. Char, et al., Global tuberculosis report 2015, World Health Organization.
- [3] N. Bellaviti, F. Bini, L. Pennacchi, G. Pepe, B. Bodini, R. Ceriani, C. D'Urbanzo, A. Vaghi, Increased incidence of spontaneous pneumothorax in very young people : Observations and treatment, *Chest* 150 (4) (2016) 560A.
- [4] C. Qin, D. Yao, Y. Shi, Z. Song, Computer-aided detection in chest radiography based on artificial intelligence : A survey, *Biomedical Engineering Online* 17 (1) (2018) 113. doi :doi :10.1186/s12938-018-0544-y.
- [5] L. Delrue, R. Gosselin, B. Ilse, A. Van Landeghem, J. de Mey, P. Duyck, Difficulties in the interpretation of chest radiography, in : Comparative Interpretation of CT and Standard Radiography of the Chest, Springer, 2011, pp. 27–49. doi :<https://doi.org/10.1007/978-3-540-79942-9>.
- [6] N. Crisp, L. Chen, Global supply of health professionals, *New England Journal of Medicine* 370 (10) (2014) 950–957. doi :<https://doi.org/10.1056/NEJMoa1312500>.
- [7] T. Atlantic, Most of the world doesn't have access to X-ray.
- [8] M. Annarumma, S. J. Withey, R. J. Bakewell, E. Pesce, V. Goh, G. Montana, Automated triaging of adult chest radiographs with deep artificial neural networks, *Radiology* 291 (1) (2019) 196–202. doi :<https://doi.org/10.1148/radiol.2018>
- [9] G. Litjens, T. Kooi, B. E. Bejnordi, A. A. A. Setio, F. Ciompi, M. Ghafoorian, J. A. W. M. van der Laak, B. van Ginneken, C. I. Sánchez, A survey on deep learning in medical image analysis, *Medical Image Analysis* 42 (2017) 60–88. doi :<https://doi.org/10.1016/j.media.2017.07.005>.
- [10] P. Rajpurkar, J. Irvin, K. Zhu, B. Yang, H. Mehta, T. Duan, D. Ding, A. Bagul, C. Langlotz, K. Shpanskaya, et al., ChexNet : Radiologist-level pneumonia detection on chest X-rays with deep learning, *arXiv preprint arXiv* :1711.05225.
- [11] Q. Guan, Y. Huang, Z. Zhong, Z. Zheng, L. Zheng, Y. Yang, Diagnose like a radiologist : Attention guided convolutional neural network for thorax disease

classification, arXiv preprint arXiv :1801.09927.

[12] P. Rajpurkar, J. Irvin, R. L. Ball, K. Zhu, B. Yang, H. Mehta, T. Duan, D. Ding, A. Bagul, C. P. Langlotz, et al., Deep learning for chest radiograph diagnosis : A retrospective comparison of the CheXNeXt algorithm to practicing radiologists, PLoS Medicine 15 (11) (2018) e1002686. doi :<https://doi.org/10.1371/journal.pmed.1002686>

[13] P. Kumar, M. Grewal, M. M. Srivastava, Boosted cascaded convnets for multilabel classification of thoracic diseases in chest radiographs, in : ICIAR,2018, pp. 546–552. doi :[https://doi.org/10.1007/978-3-319-93000-8\\_62](https://doi.org/10.1007/978-3-319-93000-8_62).

[14] ReCoNet : Multi-level Preprocessing of Chest X-rays for COVID-19 Detection Using Convolutional Neural Networks Sabbir Ahmed, Moi Hoon Yap, Senior Member, IEEE, Maxine Tan, Md. Kamrul Hasan, Senior Member, IEEE



## Rapport de projet de fin d'année



### Résumé

We propose a deep learning approach for accurate classification of thoracic diseases from chest X-ray (CXR) images. By training deep convolutional neural networks (CNNs) on a large-scale CXR dataset, we leverage the power of deep learning to learn disease-specific patterns and features. Our approach incorporates label smoothing techniques and exploits disease dependencies for improved performance.

Extensive experiments on a hidden test set demonstrate the effectiveness of our deep learning algorithm, achieving performance comparable to human specialists in disease classification. Additionally, we develop a user-friendly web interface for seamless integration of our model into clinical workflows.

Our project contributes to advancing thoracic disease diagnosis by harnessing deep learning and large-scale datasets. The developed computer-aided diagnosis system shows promise for enhancing diagnostic accuracy and efficiency in clinical practice.

**Mots clés : CNN, FastAPI, DeepLearning, Medical imaging, Cloud.**

### Abstract

En entraînant des réseaux neuronaux convolutionnels profonds (CNN) sur un ensemble de données CXR à grande échelle, nous tirons parti de la puissance de l'apprentissage profond pour apprendre des modèles et des caractéristiques spécifiques à la maladie. Notre approche intègre des techniques de lissage des étiquettes et exploite les dépendances entre les maladies pour améliorer les performances.

Des expériences approfondies sur un ensemble de tests cachés démontrent l'efficacité de notre algorithme d'apprentissage profond, atteignant des performances comparables à celles des spécialistes humains dans la classification des maladies. En outre, nous développons une interface web conviviale pour l'intégration transparente de notre modèle dans les flux de travail cliniques.

Notre projet contribue à faire progresser le diagnostic des maladies thoraciques en exploitant l'apprentissage profond et les ensembles de données à grande échelle. Le système de diagnostic assisté par ordinateur développé est prometteur pour améliorer la précision et l'efficacité du diagnostic dans la pratique clinique.

**Keys words :** CNN, FastAPI, DeepLearning, Medical imaging, Cloud.